

AI Infra: 加速智能体落地的基础架构 发展趋势与产业实践



目录

IDC观点	01
第一章 从业务需求到技术重构：AI Infra发展趋势	03
1.1 从提升技术能力到关注业务，AI应用驱动AI Infra演进	04
1.2 AI Infra发展趋势	06
1.3 AI Infra关键能力	10
第二章 从架构到场景：AI Infra的行业适配深耕	15
2.1 交通出行：平衡高效与安全，驱动“模型+数据”双轮进化	16
2.2 工业制造：私有化部署+高性能计算，打造智能中枢	18
2.3 教育行业：聚焦分布式训练加速、推理加速与数据治理	21
2.4 泛互联网和IT服务：全维度高性能支撑严苛的智能化需求	23
2.5 具身智能：赋能“脑-身”协同机器人，助力多模态感知与自主决策范式构建	26
2.6 医疗行业：构建高性能分布式算力底座与多模态数据治理引擎	29
第三章 腾讯云智算赋能千行百业：行业智能化落地实践	33
关于腾讯云智算	58

IDC观点

AI Infra（AI云基础设施）正从基础算力平台逐渐演进为驱动企业智能化转型的核心智算基础设施。随着AI应用进入规模化落地阶段，智能体（Agent）也逐步快速渗透到各个行业，企业对智算设施的需求已经从单纯的算力供给转向为业务赋能，从而实现性能优化、成本管控、运营效率、安全保障以及应用落地等全方位赋能。AI Infra 具备如下核心特征：

- **基于分布式架构的AI Infra 底座：**分布式的AI Infra 底座为企业提供了灵活弹性的智算平台构建方案，支持基于混合云架构的、云边一体的算力布局与调度，实现AI模型和应用开发的全流程管理；
- **异构的AI Infra 硬件：**异构的AI Infra硬件以多元化的智算芯片、高性能存储和智能网络设备为基础，与企业传统通用云平台硬件进行融合，构建起统一纳管的异构计算资源池，为企业智能化升级提供坚实的基础；
- **高性能的AI Infra 软件：**AI Infra是当前企业进行AI应用实践的技术框架，并逐渐演进为企业核心的智算技术平台。高性能的AI Infra软件从智算基础设施和平台的角度，通过异构计算、高性能存储和高性能网络组件，充分发掘AI Infra硬件性能；
- **提供基于场景化服务能力形成的行业解决方案：**企业在进行AI业务和应用拓展过程中，AI Infra基于分布式底座、异构硬件和高性能软件为其提供场景化的技术方案，包括模型训练/微调、在线/离线推理、模型准确率优化、智能体开发，以模板化方案构建的方式帮助企业高效地进行新型业务支撑和应用实践。

IDC认为，AI Infra应具备六大核心能力：

- **异构算力调度能力：**针对当前算力多元化的发展趋势，AI Infra通过算力调度技术和平台，实现对异构算力芯片的深度适配和统一纳管，能够根据不同业务场景进行高效的算力选型、编排和分发。
- **智能应用支撑能力：**基于云原生调度编排、微服务框架和高性能应用服务，AI Infra针对智能应用提供开发、部署、运维的全生命周期管理，具备支撑复杂多业务场景智能应用的能力。

- **全链路数据管理能力：**基于湖仓一体对数据采集、清洗和预处理流程的支撑能力，以及向量数据库对向量数据检索的支撑能力，AI Infra具备针对AI模型开发和部署的全链路数据管理能力。
- **训推一体化和加速能力：**AI训推平台针对AI模型训练/微调和推理框架的支撑能力，以及对于AI训推流程的加速能力，成为AI Infra在AI模型开发层面的核心技术平台。
- **安全体系构建能力：**基于隐私计算和联邦学习的核心安全能力，AI Infra融合基础云安全能力，构建适配AI模型和应用的智算安全体系，保障AI模型和用户敏感数据的安全。
- **全流程场景化服务能力：**针对智能体（Agent）在各行业领域加速应用的趋势，AI Infra具备支撑智能体开发与应用全流程的场景化服务能力，为MCP等智能体相关技术提供了稳定的运行环境。

在面向行业的具体落地过程中，AI Infra结合不同行业的业务特性，提供适配的部署模式、资源配置和技术能力，满足从算力管理到AI应用落地的全流程需求。AI Infra基于行业性AI业务和应用需求视角，具备云边一体的算力池化、调度与管理能力，云原生的应用开发、运维，全链路的湖仓一体、向量数据检索能力，一体化的训推框架、训推加速能力，以及体系化的基础云安全、模型安全和数据安全。在交通出行行业，AI Infra通过云边端协同架构，实现车路协同、多模态感知等关键能力，推动智能出行与交通管理革新；在工业制造领域，依托实时数据处理与分布式算力，优化生产全流程，实现柔性制造与供应链智能决策；教育行业则借助训练加速、向量数据库等技术，构建个性化学习与智能教学新范式；泛互联网与IT服务依赖其高并发支撑与敏捷扩展能力，保障业务快速迭代；具身智能通过多模态融合与云边端协同，赋予机器人精准感知与实时决策能力；而医疗行业则基于高性能算力与隐私计算，推动AI诊疗、精准药物研发等场景落地。

AI Infra基于行业智算业务和智能应用现状洞察，提供场景化的支撑能力和技术方案。AI Infra具备灵活的算力适配、弹性的资源交付和丰富的技术特性，能够根据各行业细化的需求异同，构建模板化的智算基础设施和技术平台部署，并提供智能应用和智能体的开发、运维方案。

01

从业务需求到技术重构 AI Infra发展趋势

1.1 从提升技术能力到关注业务，AI应用驱动AI Infra技术演进

当前，AI Agent（智能体）和生成式AI等先进AI技术在多个领域已经展现出强大的应用价值，驱动全球产业智能化升级。从通用场景到特定行业场景，从单点应用到企业全业务流程，行业智能化先行者不仅积极构建智能营销、数字员工等应用场景，更致力于通过数据资产重构和智能服务开发，探索全新的商业模式和增长曲线。这种探索正从技术验证迈向规模化应用，通过效率跃升和商业模式重构，推动产业实现革命性转型。目前智能体技术已经突破实验室阶段，在金融、制造、零售等流程标准化程度高的行业加速规模化应用。IDC数据显示，超过64%的中国企业已进入智能体的测试验证和采购培训阶段，预计到2028年中国企业级智能体应用市场规模将达到270亿美元。与此同时，生成式AI正加速渗透各个领域，2028年预计中国生成式AI占AI市场总投资规模比例将达到30.6%，突破300亿美元，五年年复合增长率（CAGR）高达51.5%。当前，软件与信息服务行业以41亿美元领跑投资规模，预计2028年将达149亿美元；此外，医疗健康、能源、制造、交通出行和教育五大行业投资增速值得关注，预计将保持在64.3%-67.2%的高速年复合增长率，展示出强大发展潜力。

AI Agent与生成式AI等AI技术的持续深化和规模化应用正在重塑云基础设施的核心范式，对云端AI能力支持体系提出了全新要求。这种由AI驱动的云基础设施演进，正在重塑整个云计算产业的技术栈和价值。在这一进程中，企业云技术布局正经历着从“资源规模导向”向“业务价值创造”的战略升级，这种转变主要体现在四个维度：

技术能力建设：夯实AI落地的底层支撑

企业在智能化转型中往往会产生搜索推荐、内容生成、语义分析、图像识别等多种AI应用需求。为满足这些高性能计算场景，企业需要可扩展、低延迟、高吞吐的AI Infra支持，通过部署高性能计算资源、采用智能化模型编排服务、建立完善的数据治理机制，以全面提升对多模态数据处理、多框架模型部署和多Agent协同的核心支撑能力。

价值导向部署：AI Infra紧贴业务路径与结果

企业不再单纯强调技术“可用”或追求计算资源的堆砌，而是更多聚焦“可创造业务价值”的AI部署逻辑，如：提升客户转化率的推荐引擎部署、降低成本的自动审核与理赔系统、提高客户

满意度的智能客服与语音助手，以及提高自动化监测与问题排障处理效率。这一转变促使云基础设施的设计与部署需要同业务场景实现深度耦合，形成“AI能力—业务指标—系统反馈”的闭环模式，使基础架构成为业务增长的推动器。在实践层面，这种耦合体现在三个维度：

- **技术架构基于业务目标设计：**将业务指标（如转化率、降低成本）转化为技术需求（如模型类型、实时性，Agent开发和运维要求）；
- **基础设施配置与业务场景动态匹配：**通过构建弹性伸缩能力，根据场景复杂度和业务峰值自动调整算力、存力和运力资源；
- **建立反馈优化机制：**基于用户行为、成本等业务数据反馈，实现架构的持续改进。

系统化升级：从试验性部署向系统化演进过渡

由于企业AI旅程涉及多个触点与平台（APP、小程序、网页、客服等），其将推动AI应用从“单点模型部署”向“多触点、一平台”的多模态模型+Agent架构转型。例如部署统一的大语言模型底座，支持客服问答、销售引导、内部助手等多种应用，随后通过多模态模型扩展至语音、图像、视频等业务场景，以及通过Agent串联各类业务逻辑。通过构建统一运维、统一安全、统一评估体系，企业将实现AI Infra的规模化运营与持续演进。

战略价值定位：从“支撑角色”走向“增长引擎”

企业在AI应用旅程中将逐步认识到，AI Infra不仅是其重要技术资产，更是实现业务跃升的核心战略资源，其将：


- 升级AI Agent模式支持业务从“人工驱动”向“智能驱动”演化；
- 提供按需扩容能力，适应市场变化与用户行为波动；
- 构建可衡量的技术投入产出比，使每一份架构投资都与业务结果挂钩。

这种范式转变的本质，是云计算从“技术支撑”向“业务赋能”的进化。随着AI成为企业核心竞争力，云基础设施正从后台支撑系统进化为战略创新引擎。企业关注的不再仅是技术实现，而是通过云与AI的协同发展创造业务价值。

1.2 AI Infra发展趋势

伴随企业AI应用从单点实验向全业务场景的深度融合，其对云基础架构的需求正发生量和质的双重飞跃。IDC数据显示，2024年中国GenAI IaaS市场同比增长165.2%，市场规模达87.4亿元人民币；随着开源模型的广泛应用以及智能体（Agent）在客服、运维等场景的落地，推理需求占比快速增至24%。

图1 中国GenAI IaaS服务市场 (训练/推理) 预测, 2024-2029



来源: IDC, 2025

AI应用正在进入规模化落地新阶段。企业不再满足于单纯的算力供给，而是要求智算设施具备**业务价值内生能力**。伴随企业对性能优化、成本管控、运营效率、安全保障以及应用落地的全方位需求升级，传统云基础架构正面临挑战。为满足AI时代企业规模化实现数智化转型的需求，云服务应推进向AI Infra架构的演进，以更好支撑企业大模型训练推理、数据智能、应用开发等核心场景。

在这一过程中，企业对AI Infra提出了七大关键需求：

- ④ **卓越性能：**获取高性能算力资源支持大模型训练；面向推理场景提高云准备度，降低时延，应对高并发。

- ◎ **数据效能**：让孤岛数据变成流动的知识，提高数据准备度，挖掘数据价值，构建面向AI的数据库和数据湖。
- ◎ **化繁为简**：面对规模化的数据、复杂的基于分布式云架构的AI Infra，需要保障高效的资源和流程管理。
- ◎ **专用适配**：企业基于场景化服务、弹性架构等服务，确保基础设施与解决方案匹配自身实际业务需求。
- ◎ **成本优化**：面向企业AI模型开发的训推一体化，以及AI Agent应用逐步深入的大趋势，针对AI模型的分布式训练、加速微调、边缘推理，Agent开发和运维等场景的业务峰谷特征，提升算力的调度能力，实现成本优化。
- ◎ **增强安全**：在进行AI模型所需训练/微调数据的采集，以及Agent调用模型过程中，涉及的数据安全以及AI模型安全问题已成为企业的核心关注点；对于AI模型相关数据的全链路敏感数据识别和处理，以及隐私计算、联邦学习等安全技术的引入是增强企业安全的重要环节。
- ◎ **应用支撑**：针对生成式AI模型和Agent所构建应用设计、开发、交付、运维全流程的技术支撑能力，包括开发环境、中间件、技术框架等的迭代和发展；针对AI应用运行环境的智能运维能力，包括智算基础设施和智算技术平台的AI驱动运维工具。

AI Infra通过整合高性能计算、存储、网络、数据库、安全等全栈能力，提升企业AI项目的落地效率，促进“云智融合”战略价值的进一步深化。基于智算基础设施（IaaS）和智算技术平台（PaaS）构建的AI Infra继承了云基础架构分布式、高可用的技术特性，同时基于云基础架构原生构建的模式，AI Infra能够帮助企业快速搭建支撑不同业务的AI应用平台，在生成式AI高速发展时期持续进行大模型的创新，充分挖掘企业云基础架构的价值。与此同时，MCP等标准技术栈的引入增强了智能体（Agent）的开发和调用效率，而对于异构模型的调度和管理则是智能体的关键能力。

为满足上述需求，IDC认为，AI Infra正加速向架构重构、行业垂直化、生产范式革新、可信智能体系、算力智能化和服务转型等六大方向演进，且智能体的崛起更将这一进程推向新高度。

趋势一 架构重构：构建新一代智算基础设施

AI Infra正在经历从“云+AI”的传统架构向“云原生+Agent协同”架构的深度转型，核心特征包括：

- ◎ **云原生架构**：容器和Serverless支撑Agent运行时环境
- ◎ **Agent协同架构**：支持多Agent协同工作
- ◎ **内存优化设计**：支持Agent长周期上下文保持
- ◎ **分布式训推一体化**：分布在云边端的算力支持训推一体化架构
- ◎ **异构算力池化**：满足GPU/TPU智能算力统一调度
- ◎ **实时推理网络**：支撑 μ s级延迟满足Agent连续决策需求

趋势二 行业垂直化：基于场景化的AI能力交付

AI Infra正从通用能力向场景化的行业解决方案演进，Agent成为落地载体。核心特征包括：

- ◎ **行业Know-how与云原生技术的深度融合**
- ◎ **开箱即用解决方案**：支持场景化AI解决方案快速交付
- ◎ **领域知识库集成**：Agent自动调用行业数据库
- ◎ **多模态交互**：语音/视觉/文本多通道协同

趋势三 算力智能化：全局资源优化配置

算力管理进入智能化阶段，关键特征包括：

- ◎ **管理能力**：异构算力的统一纳管
- ◎ **调度能力**：智能化的资源调度与编排
- ◎ **扩展性**：动态扩缩容能力

- ◎ **细粒度算力运营**：算力标签体系、性能预测模型、智能调度算法
- ◎ **专属优化**：动态资源分配、边缘Agent轻量化

趋势四 安全能力提升：安全合规新范式

AI Infra的安全能力正在经历从“基础云安全”到“可信立体的安全体系”的升级，核心特征包括：

- ◎ **隐私计算**：数据存储/传输/计算全生命周期隐私保护
- ◎ **行为审计**：区块链存证Agent决策链
- ◎ **数据安全**：字段级加密、动态脱敏
- ◎ **联邦学习**：数据隔离环境下Agent协同进化
- ◎ **对抗防御**：防止Agent被诱导泄露敏感信息
- ◎ **模型安全**：对抗训练、水印溯源
- ◎ **合规认证**：等保2.0、GDPR适配
- ◎ **高可用性**：灾备与业务连续性保障
- ◎ **伦理约束**：代码化植入行业合规规则

趋势五 研发范式革新：标准化AI研发体系

AI研发过程中的开发运维模式正在发生根本性变革，核心特征包括：

- ◎ **AgentOps**：Agent行为轨迹审计，多Agent协作效能评估，Agent策略博弈仿真，Agents风险预测、Agent根因分析等
- ◎ **MLOps**：机器学习全生命周期管理
- ◎ **模型训推**：自动化模型训练与部署流水线

- **AIOps**：持续集成/持续交付(CI/CD)的AI实践，云基础设施智能诊断分析，应用智能观测，预测性运维，运维智能体，运维服务化的实践
- **模型管理**：模型版本控制与监控体系

趋势六 服务化转型：AI能力普惠化

AI能力交付模式随着AI应用模式变化不断演进，将AI能力转化为模块化、标准化、易获取的服务，加速AI技术平权。核心特征包括：

- **Agent服务化**：API市场调用预置Agent能力、基于调用量计费的Agent订阅制、基于企业知识库训练专属Agent
- **标准化AI能力**：模块化、原子化的AI能力交付
- **服务形态**：Serverless化AI服务
- **API市场**：API经济与AI能力开放
- **付费模式**：按需付费的商业模式
- **应用开发**：低代码/无代码AI开发平台

1.3 AI Infra关键能力

为有效支撑上述需求和趋势，AI Infra发展出完整的四层架构：基于分布式架构的AI Infra底座层、异构的AI Infra硬件层、高性能的AI Infra软件层，以及基于场景化服务能力形成的行业解决方案层。

图2 AI Infra架构全景图



来源: IDC, 2025

分布式AI Infra底座

基于分布式、混合云架构的AI Infra底座，使得智算基础设施能够基于公有云可用区、专有云平台

和边缘计算环境，从能力上具备大规模、高性能、易扩展、易运维的特性，从而使AI Infra可以根据不同部署环境

和应用场景进行灵活的功能裁剪和资源调配，更好地应对AI应用在云边端侧灵活部署的需求，同时使得AI Infra能够很好地适配智算基础设施基于混合云架构的统一管理模式。

异构AI Infra硬件

由于AI应用的多样化特性，异构的计算、存储、网络等硬件组成了AI Infra的硬件基础。在计算方面，AI Infra对于多种算力芯片的支持成为核心能力，包括CPU、GPU、TPU、XPU等高性能智能算力芯片；在存储方面，AI Infra具备对于多种存储架构和接口硬件的统一管理能力，支撑多模态数据的高效存储；在网络方面，AI Infra支持各类智能网络设备和网卡，具备构建高性能网络的基础能力。

高性能AI Infra软件

智能计算提供异构高性能算力池（GPU/XPU等）、弹性伸缩（自动扩缩容）、算力切分（通用GPU/国产化GPU）、虚拟化卸载、高性能计算等技术能力，智算存储提供高性能文件存储、训推存储加速、数据分层、Checkpoint缓存等技术能力，智算网络则提供InfiniBand和RDMA支持（低延迟通信）、网络卸载、跨云互联（专线或SD-WAN）。

算力调度作为AI Infra调度与管理的核心平台能力，从资源管理层面来看，具备了异构芯片算力的适配兼容能力。其基于通用计算、智能计算、高性能计算任务所需的异构算力，可进行跨集群和智算中心的感知和聚合，并使用分布式路由技术自动化交付不同用户和业务应用。智能算力作为目前需求量最高的算力类型，算力调度平台针对智能算力具备广泛的兼容能力，包括CPU、GPU、XPU等主流算力芯片类型，同时适配主流的国产化算力芯片。对于行业用户而言，算力调度未来会成为AI Infra的核心能力，能够很好地屏蔽异构算力硬件的差异性，将这些硬件根据业务特性抽象为具备不同能力的算力资源，同时将大规模的算力资源通过智能路由技术联接、形成分布式的算力资源池，逐渐形成算力模型，针对不同业务储备算力，进行算力运营，从而提升整体算力的业务匹配度和利用率。

AI Agent服务平台针对目前智能体快速发展的趋势，提供对智能体开发和应用的支撑能力，从Agent运行时和开发、Agent可观测和安全方面提供沙箱运行容器、分布式代理、模型客户端和上下文、MCP Server等技术栈和工具链，为行业客户提供Agent全栈开发和运维技术平台，构建完善的Agent应用支撑体系。

AI训推平台提供模型开发流程中的分布式模型训练、高效模型微调、在线/离线推理的完整技术框架以及用于优化训练/微调/推理的技术特性，帮助行业客户充分利用智能基础设施加速模型开发全流程。

AI数据管理平台提供GenAI全链路的数据处理和分析能力，包括数据库（向量、时序）、湖仓一体、大数据分析、流式计算、数据预处理，帮助企业实现对模型开发全量数据的统一治理和高效集成，提升模型开发效率和准确率。另外针对云原生架构GenAI应用的云原生能力，提供云原生调度编排、微服务框架、高性能应用服务，帮助企业快速构建AI应用的开发、部署、运维全流程技术体系。

与此同时，智能运维和开发运维一体化也已经成为AI Infra调度与管理的重要平台能力。智能运维提供统一资源编排（Kubernetes+Serverless）、AIOps（运维工具链）、FinOps（成本优化）、运维Agent（运维智能体）。开发运维一体化提供AI开发环境和工具、MLOps（开发运维一体化）、模型管理。针对智算基础设施，运维Agent开始在企业运维场景逐步应用。运维Agent主要聚焦于故障排查和诊断场景，充分利用AI大模型的推理能力进行综合的故障根因推断，同时构建运维知识库，为运维人员提供问题咨询与信息检索能力。

针对AI Infra的安全合规能力当前逐渐成为企业关注的重点。安全合规包括AI Infra安全体系、模型安全能力、数据安全保护等核心安全能力的构建，采用模型开发全链路的敏感数据筛选和脱敏技术，引入模型防御机制如对抗训练、敏感性分析，应对模型窃取、投毒、推理攻击等新型安全威胁，建立模型注册、评估、监控与退役机制，形成标准化模型治理流程，并构建完整的行为日志系统以实时监测并记录访问与模型使用行为；针对AI在边缘或端侧，则部署环境嵌入硬件安全模块（TPM）、安全启动机制和设备行为监测策略。基于上述技术能力和管理机制，帮助企业在进行深度GenAI实践过程中提升安全合规等级，保护GenAI的核心数字资产。

针对GenAI的场景化服务能力是当前企业级AI Infra应具备的技术支撑能力，主要面向智能体开发与应用、训推一体化、模型训练、模型微调、在线/离线推理、多模态模型融合、模型准确率优化和混合数据治理等主流技术场景。

- **智能体开发与应用：**针对智能体的全流程开发平台和应用支撑平台，增强Agent一体化开发能力。采用统一的MCP协议，标准化Agent对各类AI模型的直接调用，支撑Agent在各类业务场景中的灵活应用。
- **训推一体化：**针对训推一体化场景，提供基于分布式云的“中心云训练+边缘云微调+边缘/端侧推理”模式，同时提供算力调度、任务调度编排、强化学习（RLHF/DPO）、MLOps等技术能力，以及标准化算子库、全流程模型开发工具链。

- **模型训练：**针对大规模分布式模型训练场景，提供智算基础设施和智算技术平台，同时提供算力切分、预训练加速、断点续训、低代码/可视化训练等技术能力。

模型微调：针对高效模型微调场景，提供智算基础设施和智算技术平台，同时提供模型微调

- 策略（全参微调/部分参数微调/参数高效微调）、模型微调方法（SFT微调/指令微调）、微调加速（LoRA）、低代码/可视化微调等技术能力。

在线/离线推理：针对在线/离线推理场景，提供智算基础设施和智算技术平台，同时提供主

- 流推理模型（DeepSeek/Llama/Qwen）、推理加速（算子融合/高性能加速库/模型量化/PD分离）、大语言模型和多模态模型开箱即用等技术能力。

- **多模态模型融合：**针对多模态模型融合场景，提供大语言模型与识别模型结合构建VLA模型的能力，以及NLP、CV等小模型融合为大模型的能力。同时提供通用模型与垂类模型结合能力，实现统一的模型开发框架。

- **模型准确率优化：**针对模型准确率的优化，采用标准化RAG技术框架减轻模型幻觉，同时结合业务数据进行模型强化训练和微调。

- **混合数据管理：**针对智能体开发，提供标量和向量的多模数据处理分析能力；针对RAG流程，提供具备高检索性能和准确性的向量数据库。

02

从架构到场景 AI Infra的行业适配深耕

AI Infra的技术架构演进，为行业应用奠定了坚实基础，但其真正价值需要通过场景落地来实现。当前，AI Infra正经历从“技术能力构建”到“业务价值创造”的关键跃迁。这一转变体现在三个维度：技术架构的行业适配性持续增强，从通用计算平台进化为具备行业特征的智能底座；服务模式从标准化产品向场景化解决方案升级，实现技术与业务的深度耦合；价值创造从单点效率提升扩展到全链路业务创新。在交通出行、制造、教育、互联网与IT服务、具身智能、医疗等重点行业，AI Infra已开始赋能业务流程智能化，实现技术与行业的双向赋能。

2.1 交通出行： 平衡高效与安全，驱动“模型+数据”双轮进化



行业AI技术趋势

交通出行行业的智能化变革一方面聚焦于交通工具自身的智能跃迁，另一方面将AI技术融入至交通系统的各个层面，涵盖路况精准识别、车路协同、多模态识别等，推动交通领域从出行方式到交通管理模式的全方位重塑：

- **在应用方面**，在智能座舱领域，基于大语言模型的连续推理能力使系统可以理解复杂关联指令，提升交互自然度，通过个性化交互系统和情感化设计提升用户体验；智能驾驶方面，借助全场景驾驶辅助重构行车安全体系，多源传感器数据融合提高复杂路况识别准确率；物流行业基于大数据和AI模型提升物流车辆调度效率，优化运输行驶路径，并为供应链管理提供适用性强的智能化方案，降低运营成本，提高响应速度和服务质量；共享出行领域的网约车智能调度、共享单车供需预测等场景，需要基于实时大数据处理和AI模型分析，对车辆、服务资源进行合理配置，以持续改善用户体验。
- **在技术突破方面**，多模态大模型展现出强大潜力，显著提升路况识别效能；尤其是视觉语言模型（VLM）和视觉语言动作模型（VLA）的快速发展，实现了从环境感知到语义理解、再到行为决策的“端到端”能力跃迁。此外，车端与边缘云协同加速推理架构革新。随着边缘算力技术的快速发展，车端与边缘云的协同推理架构逐渐成为热点之一。边缘云在提升算力响应速度方面作用显著，能够帮助车端实现实时/准实时感知和决策推理，同时在云端保留模型更新、知识补全与远程运算能力，以协同方式构建高效、灵活的智能交通系统。

对AI Infra的特性需求

交通出行行业的智能化发展呈现出以模型和数据为驱动的发展态势，这对AI Infra提出更多专业化、场景化的发展需求。AI Infra既要为交通出行行业大规模模型训练任务提供强大的算力支持，又要充分满足模型在车端、路侧的高效推理需求；其更关注云边端一体化协同环境，并能够对海量数据提供高效的存储与管理服务，同时确保整个平台安全合规。

- **在计算架构层面**，智能汽车需要构建基于“中心云+边缘云+端侧环境”的分布式云基础架构，中心云需要支持千亿参数的大模型训练/微调，基于规模化、高效率、可集中调度的算力集群，支撑分布式训练业务，支撑技术快速迭代；此外，应具有良好的软件管理、调度和优化能力，以确保训练任务的连续性，以及较高的算力有效利用率。边缘云需要满足低延迟推理需求，终端设备需要适配轻量化模型部署。
- **在数据处理层面**，智能汽车AI云平台需要具备超大规模数据吞吐和处理能力，重点关注高性能存储，以存储全量原始路采车数据和预处理后的数据。同时，还需要构建高效的数据处理闭环流程，并通过湖仓一体平台等设施加速数据预处理和清洗任务，提升基础数据质量。此外，还应建立高效的向量数据库和数据处理能力，满足大模型相关任务需要。在智慧物流场景下，AI Infra需要能稳定支持车端回馈数据的持续采集，以用于模型微调，持续提升模型准确率；与此同时，还需构建弹性、低成本的数据存储服务，满足大规模物流数据的存储需求。
- **在安全合规方面**，相关管理机构对汽车和用户数据的生成、传输和使用均已提出严格的合规要求。相关基础设施既要满足合规处理要求（例如合规云），又要重视智驾相关AI模型的安全性，确保云边端的基础安全和数据安全体系的完善。

AI Infra建设要点

为应对交通出行行业复杂且多样化的业务场景，交通出行行业的AI Infra建设重点是云边端一体化协同、数据高效存储管理以及系统的安全合规建设，既满足模型在车端、端侧的高效推理需求，又为大规模模型训练提供强大算力支撑。

- **异构AI Infra硬件**：AI Infra需配备高显存、高带宽的GPU卡以及高性能通用处理器，采用RDMA技术构建高性能网络集群，兼顾强大单体算力和高性能网络协同，确保数据高效传输，加速训练和微调。

◎ 高性能AI Infra软件：

- 智能计算能够对多样化的云边算力节点进行一体化管理，具备大规模高性能计算能力，也能够运行经压缩和小型化处理（如模型剪枝、量化、知识蒸馏）后的模型，就近处理数据，减少延迟和带宽消耗。
- 智算存储具备高可扩展，并采用冷热数据分离等技术兼顾性能与成本平衡，例如将热数据存储于SSD，冷数据存储于对象存储环境和HDD，降低数据预处理和清洗任务的资源消耗。
- AI训推平台的训推加速支持低精度模型量化技术（如INT8量化），并配置具备高性能网络连接的算力平台用于计算推理过程，支撑VLA模型在车端有限算力下高效运行，同时利用大带宽网络保障数据同步，提升推理准确性。
- 安全合规重点确保模型和数据安全，在数据预处理阶段进行数据保护（加密、脱敏等），在模型训练/微调阶段引入隐私计算、联邦学习等机制，在推理应用阶段引入监控中心、输出检测等机制，提升AI开发和应用全链路安全运营能力；构建云边端一体安全体系（防火墙、入侵检测等），全方位防护以保障系统稳定。

2.2 工业制造：

私有化部署+高性能计算，打造智能中枢



行业AI技术趋势

工业制造领域正经历着深刻的智能化变革。这一变革以技术创新和场景落地为驱动力，一方面致力于构建高效、灵活且智能的生产运营体系，例如借助先进的信息技术实现生产流程的精准控制与优化；另一方面将前沿的智能技术深度融入制造的各个环节，涵盖从产品设计、生产制造到售后服务的全生命周期，推动工业制造从传统模式向智能化模式的全面转型：

- ◎ 强大的端侧推理能力加速AI落地，越来越多的AI推理任务下沉至边缘终端，使得边缘设备可利用强大的计算能力，实现设备的自主识别、状态预判与故障预测。例如，在生产线上的传感器实时采集设备运行数据，并在本地进行快速推理分析，发现异常可以立即发出警报，减少了因设备故障导致的生产中断；

- ④ 大语言模型发挥出巨大的提质增效作用，并通过智能体的快速迭代开发，优化智能问答、工单辅助、流程推荐等场景的智能化效果，为员工提供最优的工作流程建议，实现知识调用与流程智能协作，提升整体业务协同能力；
- ④ 企业将通用多模态大模型进行本地部署，并结合多年积累的生产数据对模型进行微调，使其能够更好地适应特定的生产环境和需求。这些模型应用于图像识别、质量检测、物料跟踪等关键业务，能够综合分析多种类型的数据，提高识别的准确性和可靠性，为生产过程的质量控制和物料管理提供有力支持；
- ④ 工业智能体开发和应用进入更广泛探索的阶段，工业智能体重点的方向包括企业级知识库、应用开发、计划排产调度、售后客服、日常办公辅助等。在设备故障分析、工艺优化、智能排产等业务中，企业可通过智能体的形式封装调用机理模型和传统AI小模型，实现优化提升。

对AI Infra的特性需求

随着智能制造的发展，AI Infra需要承载各类传感器产生的大规模实时数据处理任务，支持制造业企业在生成数据分析、柔性生产、产品质检和供应链优化等核心场景的智能化发展。

- ④ **在计算架构方面**，AI Infra需要提供异构高效的计算能力，满足不同场景的实时计算需求，基于通用算力芯片与主流云厂商平台，构建混合云架构，实现算力灵活调度，支持数字孪生、实时质检等业务的高效运行；在质检场景中，需兼容视觉大模型、多模态模型及传统算法，并能根据生产规模动态扩展算力资源；此外，确保平台长时间稳定运行，具备容错机制，减少因故障导致的生产中断，保障质检流程的连续性。
- ④ **在数据方面**，AI Infra需要提供高效的数据处理和存储能力。比如：利用边缘计算提升数据清洗与转换效率，确保数据质量，减少对模型效果的干扰；整合供应商、物流、销售等多环节数据，打破数据孤岛，实现供应链优化与需求预测；在质检场景中，需支持生产线数据的低延迟采集、传输与存储，并实现快速检索以支持质量追溯，打造高质量数据闭环；此外，为企业知识库提供安全稳定的存储方案，支持多模态数据（文本、图像、音频、视频）的高效检索，融合分散在CRM、ERP、文档管理系统中的业务数据，形成统一的知识决策支持体系。

- **在模型层面**，AI模型的灵活应用是智能制造的核心。所以，AI Infra需能通过支持模型微调与优化，在AIOps场景进行初步实践，分业务进行数据分析，开发Dashboard应用，实时监控生产流程，及时发现并解决问题；还需提供多类型模型的统一管理，并随市场变化而迭代，保持模型的适应性与有效性；支持多模态大模型和OCR、语音处理等传统模型结合，高效处理来源广泛的知识信息，涵盖文本、图像、音频、视频等多种形式。

AI Infra建设要点

工业制造行业的业务场景复杂多变，且数据处理需求日益增长，因而其AI Infra建设应聚焦于私有化部署、推理加速、向量数据检索以及数据存储等关键方面，以便为工业生产提供高效、稳定且安全的智能支持。

- **分布式AI Infra底座**：企业通过私有化部署的AI Infra底座构建智算平台，构建高性能智能计算、智算存储和智算网络，满足大规模数据处理与复杂模型训练需求，支撑云原生、AI数据管理、AI训推等平台化能力，为工业智能应用的快速开发与部署提供有力支撑。
- **高性能AI Infra软件**：
 - 工业制造业务产生大量业务数据，对数据存储的QPS和带宽要求极高。智算存储系统需提供高QPS和高带宽支持，提升数据批量处理速度，确保数据能够及时、准确地被算力资源调用，避免算力闲置。同时，采用先进的存储架构与管理策略，优化数据存储布局，提高存储利用率，降低存储成本。
 - 引入RAG技术减少模型幻觉，提升工业决策准确性。在此过程中，通过将数据转化为向量形式存储，利用AI数据管理平台向量数据库的快速相似度匹配能力，为模型提供精准的相关数据，辅助模型做出更可靠的决策，优化工业生产流程，提高产品质量。
 - 为提升工业模型推理效率，需借助AI训推平台的训推加速能力，引入模型量化技术对模型进行分类优化。针对端侧设备算力有限的缺陷，部署性能更优、效率更高的小型化模型，通过模型剪枝、蒸馏等手段，降低模型复杂度与计算量，实现实时响应与决策。

2.3 教育行业：

聚焦分布式训练加速、推理加速与数据治理



行业AI技术趋势

教育行业借助先进的信息技术打破传统教学的时间与空间限制，为学习者提供随时随地的学习机会，并将前沿的智能技术深度融入教学的各个环节，涵盖从课程设计、教学实施到学习评价的全过程，推动教育培训从标准化模式向个性化、智能化模式的全面转型。

- **在应用创新方面**，智能教研系统基于大语言模型的语义理解能力，可自动生成教案与习题，实现教学资源智能化生产；个性化学习系统通过多模态行为分析构建学生画像，动态调整学习路径；课堂AI助手融合语音识别与情感计算技术，实时监测课堂参与度并生成教学优化建议；智慧校园管理场景中，多模态安防系统能同时处理视频、红外与传感器数据，实现校园异常事件的智能预警与快速响应。
- **在技术突破方面**，垂类大模型和开源大模型加速落地应用。面向教育场景的专属大模型正加速落地应用，如教学问答大模型、学习行为分析大模型等，为教师、学生建立个性化的教学和学习方案提供有力支撑。同时，采用开源大语言模型实现自定义问答、智能批改、知识图谱构建等功能；例如智能批改功能能够快速准确地批改学生的作业和作文，减轻教师的工作负担，同时提供详细的批改建议和评价，帮助学生提高学习效果。此外，智能硬件与AI应用深度绑定，教育终端设备成为教学互动的智能节点，例如智能学习平板集成语音识别、图像分析等功能，使学生可以通过交互方式查询知识、完成作业，教室AI助手则能够实时监测课堂氛围，分析师生的互动情况，为教师调整教学策略提供参考，使课堂教学更加生动有趣、富有成效。

对AI Infra的特性需求

教育智能化发展对AI Infra提出三方面核心要求：需支撑海量教学数据的实时处理与分析，满足教育大模型的训练与推理需求，保障教育敏感数据的安全合规。具体表现为：

- **计算架构需求**：首先，突破传统的单一算力服务模式，构建云上规模化算力、边缘快速响应和智能终端交互的融合模式。云端存储和处理海量的教学资源与学习数据，实现教学内容的

高效管理与按需调度；边缘层为教学过程中的即时反馈提供支持，例如对在线课堂的实时状态进行监控和分析；终端设备具备智能交互能力，支持个性化推送和服务定制。其次，构建多元异构算力融合的算力环境。因科研、教学、实训的多样化需要，需对多元异构算力进行一体化管理和调度，同时需特别关注算力的扩展能力，以应对教研数据量的快速增长。异构算力环境应支持多种AI模型的并行训练与推理，提升整体教研效率。此外，提供大规模弹性算力。安防行为分析和自动化监考要实时处理大量数据，对算力要求极高，需配备强大的GPU或专用AI芯片提供算力支持；同时，不同时段、不同子场景的需求波动大，如考试期间监考任务重，需快速增加资源。

- **支持多样化模型开发和快速迭代：**能够利用技术平台快速开发题库生成模型、智能批改模型及教学成果评估模型等，依托相关技术框架进行模型训练与微调。通过中心云进行大规模模型训练，边侧和端侧进行实时推理。随着教学方法和学生需求的变化，能快速更新和优化模型，提升个性化学习效果。此外，校园环境和人员行为复杂，变化频繁，模型需求应多样化以快速适应新情况。特别是校园管理场景，对于多模态模型有较强的迭代需求，应通过结合视频、音频、传感器数据等多模态信息进行分析，提高行为识别的准确性和可靠性。
- **数据处理需求：**多元数据高效整合与处理，构建完善的数据处理闭环体系，能融合学生的学习成绩、课堂表现、作业情况、在线时长等多源数据，全面了解学生特点，并持续优化模型分析性能。湖仓一体高效数据管理，即利用湖仓一体技术实现数据的统一管理 with 高效利用，为个性化学习提供数据支撑；教研数据多样化且复杂度高，需构建湖仓一体技术体系，实现数据的统一存储、处理与分析，并利用沉淀的大量教研相关数据，持续优化模型性能，提升教研效率与教材质量。
- **安全合规：**校园管理涉及大量敏感数据，需严格遵守相关法律法规要求，确保数据安全与隐私保护。通过引入数据加密、访问控制等安全技术手段，构建安全合规的校园AI数据管理平台。

AI Infra建设要点

为满足教育行业多样化的业务需求，AI Infra基础设施的建设重点聚焦于分布式训练加速、推理加速、向量数据处理、开发运维一体化以及数据闭环等方面。

- 采用算力调度技术实现调度与管理能力，提高算力使用率，避免资源闲置，同时借助训练加速平台的数据IO优化、计算优化、通信优化、并行训练、显存优化等一系列技术，构建分布式训练环境，从多个维度提高训练效率，推动教育大模型快速落地。
- 教育行业企业沉淀了大量教研相关数据，类型多样、复杂度高，采用向量数据库进行向量数据的高效存储和管理，提供Embedding模型和语义级别的检索能力，支撑教育大模型的不断优化和提升。采用湖仓一体解决方案构建全链路数据汇聚和分析平台，能够整合不同来源、不同格式的教育数据，实现数据的高效存储、管理和分析，为教育模型的持续优化提供有力支持。
- 教育行业的端侧设备数量众多、类型丰富，为实现高效推理，需进行大量的端侧模型小型化部署。通过AI训推平台的推理加速能力，引入模型量化技术，将模型进行适当压缩和优化，在有限的算力基础上提供高效的推理能力，能够确保教育应用能够实时响应，为学生和教师提供流畅的使用体验。

2.4 泛互联网和IT服务： 全维度高性能支撑严苛的智能化需求



行业AI技术趋势

借助无处不在的互联网连接和高效弹性的AI Infra，泛互联网和IT服务行业正持续将前沿的智能技术深度嵌入到产品开发、运营维护、客户服务等各个业务环节中，让智能服务如影随形，实现从“连接赋能”向“智能驱动”的范式升级。

- ◎ **智能体承载复杂业务：**智能体融合多领域数据与先进算法、具备超强自主学习和通用能力。其能够精准洞察用户需求，提供个性化服务；优化业务流程，提升行业效率；还能够驱动创新，助力互联网生态持续进化。在IT服务领域，低代码开发智能体能够帮助开发者快速搭建应用程序；即使是缺乏专业编程知识的业务人员也能在智能体的辅助下完成应用开发，推动智能服务的普及和创新。
- ◎ **AI模型泛化能力受到广泛重视：**泛互联网不同用户和场景数据存在显著差异，AI模型必须具备更强的泛化和迁移能力，才能在面对新的用户群体和业务场景时，保持稳定的性能表现。

- **视觉垂类模型引领业务创新：**构建视觉大模型生产流水线，实现从数据标注、模型训练到边缘部署的全流程自动化。短视频平台依托千卡集群完成日均PB级视频内容的理解与分类，直播平台通过实时视觉分析实现违规内容毫秒级拦截。
- **多框架协同与生态开放发展：**用户需求呈现显著的多样化趋势，智算技术平台需要支持多类技术框架，增强智能化平台的灵活性，通过开放的生态体系满足不同开发者的使用习惯和需求，并支持模型在不同平台之间的快速迁移、复用和跨平台部署。
- **模型轻量化加速端侧落地：**为了满足不同终端设备的算力配置与能效要求，小型化模型成为行业开发的重点。通过采用轻量化模型结构，结合量化、剪枝等技术，有效降低模型的计算复杂度和存储需求，使AI应用能在低功耗设备上稳定运行。
- **移动智能革命：**端侧AI计算能力的提升催生新一代“智能体应用”，APP从信息载体进化为具备自主决策能力的数字代理。庞大的用户规模使得移动端积累了丰富且多样的数据，用户与APP之间频繁的交互行为更为AI模型的训练提供了大量鲜活的素材。这些因素促使开发者不断推动模型向端侧适配和优化，以实现更快速、精准的响应。

对AI Infra的特性需求

泛互联网和IT服务行业的AI Infra长期为海量用户和复杂业务场景提供坚实支撑，持续应对高并发的访问请求，并全力确保服务的稳定性和可靠性。为了快速适应不断变化的业务需求，该领域着重关注相关功能的灵活扩展能力和迭代效率。

- **大规模智能算力弹性支撑：**图像和视频数据量大、计算复杂，需要集群化的GPU或专用AI芯片，以快速处理海量像素数据，完成特征提取、模型推理等任务。业务量波动时，AI Infra要能按需灵活扩展算力，避免资源浪费或不足；
- **高效数据传输网络和高性能存储：**图像/视频数据传输量大，需高速稳定的网络，确保数据能及时从采集端传到处理端，减少延迟。同时，针对海量的原始图像/视频数据以及处理后的结果，需配备大容量、高可靠和快速读写的存储方案，随后对输入的原始数据进行清洗、标注、特征提取等预处理操作，为内容生成模型提供高质量、规范化的数据，提高生成效果和效率。

- **支持数据闭环能力：**利用业务沉淀数据优化模型，并利用湖仓一体技术管理异构数据，通过全链路数据管理平台构建数据闭环。强化ETL能力以实现训练数据的高效处理与利用，提升推荐系统的准确性和实时性。
- **模型层面：**支持模型快速部署和优化，能快速将训练好的图像/视频识别模型部署到生产环境，提升迭代效率，支持对模型进行量化、剪枝等优化，提高推理速度，同时尽量不损失识别精度；多样化模型适配和模型快速迭代，为应对复杂多变的用户端需求，需支持多种推荐算法模型以便在统一的管理下根据不同场景和商品类型灵活选用，并能随着市场和用户需求变化快速更新模型，融入新数据和算法，优化推荐效果；支持多模态模型，聚焦于GenAI大模型的开发与优化，支持文本、图像、音频、视频等多模态内容生成模型的运行，实现不同模态之间的转换和融合，满足多样化的内容生成需求，同时还需关注模型在边缘/端侧的推理性能，以支持实时内容生成需求。
- **安全合规：**在数据收集、存储、分析和共享过程中，需严格遵守相关法律法规要求，确保用户数据的安全和隐私保护。采用数据加密、访问控制等安全技术手段，防止数据泄露和滥用风险。

AI Infra建设要点

AI技术的广泛应用正重塑泛互联网和IT服务行业的业务模式与服务体验。为充分发挥AI的潜力，AI Infra需关注数据存储、算力调度、向量数据检索、数据闭环、数据安全性以及开发运维一体化等多个重要方面。

- **分布式AI Infra底座：**基于私有化部署的AI Infra底座构建智算平台，包括智能计算、智算存储和智算网络，以及AI应用、数据、模型支撑平台，满足大规模数据处理与复杂模型训练需求，支撑云原生、AI数据管理、AI训推等平台化能力，为企业智能应用的快速开发与部署提供有力支撑。
- **高性能AI Infra软件：**
 - 模型训练对训练数据的存取效率要求极高。为满足这一需求，需借助高性能文件存储提供高吞吐低延迟的文件存储服务，确保数据能够快速、稳定地读写。同时，采用存算分离的存储架构，将存储与计算资源解耦，根据实际需求灵活分配资源，进一步提升数据存取效率，避免因存储瓶颈影响模型训练进度。

- 通过算力调度技术构建调度与管理能力，对各类算力资源进行统一管理和优化调度，实现大规模异构算力资源的高效管理、编排与分发。此外，利用高性能网络提升算力调度效率，降低数据传输延迟，满足模型训练中分布式并行计算对低延迟的严格要求，确保训练任务能够快速、稳定地完成。
- 湖仓一体能够支持AI数据管理平台对训练数据进行全面管理，包括数据的传输、存储、清洗及加工等环节，确保数据的质量和一致性，为模型训练提供高质量的数据支持，推动模型性能不断提升。
- 采用查询混淆和随机化等安全合规技术进行数据脱敏，防止敏感信息泄露，提升本地化数据的安全性。同时，构建全栈安全防护体系，从数据的全链路进行本地化数据安全保护，抵御各类网络攻击和数据安全威胁。

2.5 具身智能：赋能“脑-身”协同机器人，助力多模态感知与自主决策范式构建



行业AI技术趋势

具身智能行业是当前科技变革的前沿，致力于打造能够深度融入物理世界并与人类自然交互的智能体。通过将前沿的AI技术与机械工程、认知科学等多学科深度融合，该行业正推动机器人从简单的执行工具向具备自主认知、决策和行动能力的智能伙伴全面进化。

- ◎ **“大脑+小脑”协同发展驱动类人智能架构逐步成型：**机器人系统正朝着模拟人类神经机制的方向加速演进。大脑模型如同人类的思维中枢，聚焦于语义理解、意图识别、任务拆解与逻辑推理等高级认知功能，能准确理解人类的语言指令，分析任务的复杂程度，并将其拆解为一系列可执行的子任务。小脑模型则专注于动作控制、感知融合与空间协调，精准控制机器人的每一个动作，支撑机器人顺利执行各类物理任务。
- ◎ **仿真环境与世界模型持续完善：**基于对物理世界规律的深刻认知和丰富经验，开发人员利用仿真平台对物体运动、形变、环境的光电气热变化以及操作工具使用等现象、状态和过程进行细致的仿真和建模，为机器人构建起对物理世界和动作控制的全面认知。同时，持续的仿真训练能够对机器人的运动控制算法进行优化调整，使其在不同场景下都能进行精准、高效的动作执行。

- ◎ **机器人认知与动作闭环日益增强：**在具身智能应用系统中，语义指令成为驱动机器人动作执行的关键。大脑模型与小脑模型之间形成了更强的反馈机制，大脑根据任务需求发出指令，小脑负责执行动作并将执行结果反馈给大脑，大脑再根据反馈信息实现自主决策与状态调整，使机器人能够更加智能地应对各种复杂情况。
- ◎ **多模态交互成为核心能力：**视觉、语音、触觉等多种感知能力的深度融合，结合语义推理与策略执行，为机器人带来了更自然、人性化的人机交互体验。例如机器人可以通过视觉感知周围环境，用语音与人类进行流畅对话，或者通过触觉感知物体的质地和形状，更全面地理解人类的需求并提供相应的服务。
- ◎ **云边端协同体系加速构建：**在具身智能领域，算力规模化与实时性需求的双重挑战推动AI能力在云端训练、边缘推理与端侧控制之间进行动态协同——云端支撑大规模模型训练和优化，边缘设备在本地实现快速推理，端侧控制算法确保机器人能够实时响应环境变化。这种协同体系能够兼顾智能水平与响应速度。
- ◎ **模型向融合与轻量化方向演进：**以大模型技术和多源异构的环境感知数据为基础，通过持续的迭代训练，让机器人形成对感知世界的经验认知与理解；特别是在人形机器人领域，大模型基于多模态数据提升机器人的感知能力，推动机器人的自主学习、决策规划能力，并与机器人的动作训练、行为交互训练结合。同时，通过模型轻量化，提升部署效率与场景适应能力。

对AI Infra的特性需求

具身智能行业的AI Infra建设需要为机器人在复杂物理环境中的稳定运行和高效交互提供坚实保障，通过对海量多模态数据的实时处理，实现精准的感知与决策，同时具备快速响应能力，确保机器人动作的流畅和准确。此外，具身智能领域对AI安全机制的要求较高，以充分保障机器人与人、环境交互过程的安全性。

机器人动作和行为控制：AI赋能的智能协同模式

当前，机器人领域在本体控制和群控方面正在积极引入AI模型，借助大语言模型和多模态融合模型，逐步实现类似大脑的语义理解以及类似小脑的动作协调功能，从而展现出强大的智能交互与协作潜力。动作和行为控制场景对AI Infra的核心需求如下：

- ◎ **混合云架构智算基础设施：**通过“中心云+边缘环境+端侧”的混合算力基础架构，为机器人
大脑和小脑模型协同推理提供坚实支撑，确保复杂任务的实时处理。云边端网络通信的稳定
性与低时延是保障机器人群控效率的关键因素，使机器人单体和机器人之间能够实现高效信
息交互与协同作业。
- ◎ **边缘侧模型开发环境：**在边缘侧构建丰富算力，开展多模态聚合模型的训练与微调工作，并
主要部署于机器人端侧，支撑“大脑+小脑”协同工作模式。同时，为提升模型性能，相关
基础设施需强化对数据的高性能存储和处理能力，以通过高质量、多样化的数据训练，增强
模型的泛化能力和准确性，驱动机器人更好适应复杂多变的环境与任务。
- ◎ **训推一体化支撑：**AI Infra应有效支撑训推一体化需求，利用分布式训练环境加速模型迭代，
并支持多种模型微调方法，快速适应新场景需求；利用推理加速技术（如模型量化、PD分
离）降低推理延迟，提升机器人响应速度；利用边缘/端侧推理能力确保机器人实时决策效
率。此外，需采取严格措施保障训练数据集的安全性，确保机器人系统的稳定运行。
- ◎ **高效算力调度：**数据采集、模型训练以及机器人群控均依赖云端的实时算力支持。如何高效
率调度算力并对预训练、训练/微调、实时推理等不同阶段的算力需求进行适配，是当前行业
发展面临的难点。需充分考虑业务波峰波谷特性，实现算力的平衡分配，提高算力资源利用
率，降低运营成本。
- ◎ **数据抽取和数据更新：**提升从互联网采集数据的能力，通过全链路ETL方案构建数据飞轮基
础支撑。同时，持续的数据更新与优化能够为模型训练提供丰富素材，推动机器人性能不断
提升，实现自我进化。
- ◎ **安全合规：**数据是具身智能产业的核心资产，所以，如何在云边端环境中保持一致的数据安
全性成为相关企业的核心关注点。需建立完善的数据安全防护体系，涵盖数据加密、访问控
制、安全审计等多个环节，确保机器人系统在全生命周期内的安全与合规。

AI Infra建设要点

具身智能行业对于AI Infra的建设需求，紧密围绕多模态融合模型、VLA模型应用、端侧模型部
署、云边端一体化、数据闭环以及数据安全性等核心领域展开。

- ◎ **分布式AI Infra底座：**具身智能的应用场景丰富多样，涵盖了模型训练、微调以及推理等多个环节。AI Infra应通过网络和边缘加速平台，构建云边端算力与微调/推理框架的高效协同机制，形成云边端一体化架构，确保文本、图像、触觉信号等不同模态的数据，在端侧实现高效融合与协同处理，进而赋予机器人更全面、精准的环境感知能力以及快速、恰当的行为响应能力，提升具身智能系统整体响应速度和处理能力。

- ◎ **高性能AI Infra软件：**

- AI训推平台支撑模型开发部署全链路，通过训推加速的数据IO优化、计算优化、通信优化、并行训练、显存优化、模型量化、PD分离等一系列技术，实现VLA模型的高效训练、实时推理加速、数据驱动模型泛化，使机器人能够迅速适应各种复杂多变的应用场景。
- AI数据管理平台支撑完善的数据闭环体系，湖仓一体对回传数据进行全面收集、系统整理、深入分析和及时反馈，并通过向量数据库不断优化模型性能，推动机器人智能水平持续提升。
- 安全合规通过引入全栈安全防护技术，从数据的全链路角度出发，实现云边端一体化的数据安全保护，覆盖数据采集、传输、存储、处理等各个环节，采取加密、访问控制、数据备份、隐私计算、联邦学习等多种安全措施，确保机器人的稳定运行以及用户信息的安全可靠。

2.6 医疗行业：

构建高性能分布式算力底座与多模态数据治理引擎



行业AI技术趋势

医疗行业借助AI算法和模型的强大能力和丰富的行业数据，打破传统医疗模式的局限，从初期的优化医疗资源配置、提升医疗服务效率，到深度融入医疗环节、辅助阅读影像资料、助力疾病精准预测与早期干预，进而推动个性化医疗发展，满足多元健康需求。AI技术正在持续赋能医疗技术革新，并重塑整个医疗生态体系。

AI医疗健康领域正呈现出多元化发展趋势：在临床领域，AI与医疗大数据融合，实现更精准的疾病预测、诊断和治疗方案推荐；在医学分析领域，利用深度学习算法对病灶进行自动识别和分类，并将关键信息生成标准化报告；在医药研发领域，AI模型通过分析海量数据、预测分子结构与活性等，显著加速了药物研发过程。此外，AI能力还扩展到健康管理全链条，不断提升个性化健康服务体验。相关的技术和应用趋势包括：

- **医疗大数据深度赋能AI模型和应用：**海量、多模态医疗数据涵盖病例记录、影像资料、学术研究成果等多元行业信息，为行业大模型训练提供了丰富的原材料，推动AI在疾病诊断、药物研发、健康管理等领域大幅提升效率和精准度。例如在疾病管理应用中，AI模型通过整合多种数据源，实现疾病风险的早期预警和个性化干预；在健康管理应用中，AI模型通过整合基因组数据、临床记录、影像学数据等，构建个性化治疗方案，同时生成式AI通过人机交互能力帮助患者克服治疗障碍，为其提供替代方案。
- **虚拟医疗助手获得广泛推广：**目前，各种医疗健康应用正在大量引入虚拟医疗助手能力，通过自然语言交互能力和丰富的医学知识，为患者解答常见疾病问题、提供医疗建议以及提供医疗辅助服务等。为持续提升相关服务的效率和质量，需要持续利用新技术、新方法强化医疗大模型的专业深度和泛化能力。例如采用小样本学习技术，基于少量疾病原始材料 and 专业化标注数据，快速提升诊断精准度。
- **医疗AI应用在边缘低算力环境拓展：**大量的智能化医疗场景正在向基层和偏远地区延伸。为更大范围提升医疗诊断水平，推动优质医疗服务的普及，医疗大模型的边缘部署能力成为重要的发展目标。相关的模型轻量化改造以及边缘侧、端侧算力适配，将支撑AI模型在算力资源有限的环境中高效运行，为优质医疗资源的普及提供关键支撑。
- **AI大模型加速传统医疗经验沉淀与传承：**通过对医疗行业大模型的预训练和持续微调，结合自然语言处理和知识图谱，将医患口述转化为标准中医病证、主诉/症状等，促进名医经验的系统化传承。

对AI Infra的特性需求

医疗行业的AI Infra主要用于支撑行业场景中的AI算法和模型的开发、部署、运行，并在安全环境下利用医疗数据训练、精调行业大模型，持续提升模型的专业化能力。其对AI Infra的核心需求如下：

- **数据管理与治理方面：**支持多模态、异构数据统一管理，AI诊疗领域需要针对多种结构化和非结构化临床数据，基于湖仓一体环境建立多模态数据的采集、清洗、标签化等全链条预处理能力，并利用统一的数据管理平台实现数据库的高效检索和大数据的实时分析处理能力；海量数据高效存储，通过安全稳定、高性能的文件存储、对象存储服务，实现各类医学影像数据的高效存取，同时采用冷热数据分层技术实现医学影像数据的分级管理，进一步提升数据存取和检索的效率；数据安全保护和隐私计算环境，通过健全的数据安全防护环境，确保

大量敏感医疗数据的安全存储和应用，并利用敏感词智能识别、替换以及隐私计算等技术，强化医疗机构在AI医疗数据检索和数据预处理过程中对患者隐私数据的全方位防护能力。

- **模型训练与推理方面：**训推加速，通过AI模型训推平台进行医学影像识别和分析模型的训练/微调 and 推理加速，采用强化学习、LoRA、PD分离部署、量化/蒸馏/剪枝等技术实现AI模型的训练效率提升、准确度优化和推理能力增强；高性能计算，通过高性能计算节点和计算框架，针对高精度并行计算和AI模型训练/微调场景进行算力调度和流程加速，在医药研发过程中使用并行计算和分布式计算能力帮助研发人员进行药物成分组合的模拟分析，提升分析流程的效率；训推一体框架，通过大规模分布式训练加速AI模型训练过程，通过微调技术提升AI模型应用效果，并使用AI模型的推理能力帮助研发人员进行效力计算、合成可能性分析，制定最优配比方案。
- **多元、多模态模型融合：**生成式大语言模型和传统视觉模型的多模态融合，例如在手术机器人应用中，加强对外科手术中高难度操作的准确理解和精确执行，提升手术成功率。

AI Infra建设要点

医疗行业AI Infra需要具备高性能算力底座，以支撑各种不同类型的医疗AI模型训练与推理需求。同时，建立多源、异构医疗数据的汇聚、清洗与标注能力，为AI发展持续提供优质数据。此外，安全合规体系至关重要，须严格遵循医疗数据隐私保护法规，保障数据全生命周期安全。

- **分布式AI Infra底座：**由于智能医疗场景的多样化特性，AI Infra需具备强大的云边协同能力，通过公有云可用区、专有云平台、边缘计算环境构建的分布式底座，为各类医疗AI模型和应用提供开发、部署、运维所需的智算基础设施、训推一体化和开发运维一体化服务。
- **高性能AI Infra软件：**
 - 通过智能计算、智算存储、智算网络等智算基础设施，为医疗机构快速构建AI模型开发和部署以及AI应用的运维提供高性能算力。
 - 采用云原生平台的高性能应用服务支撑智能应用开发和运维全流程；采用AI数据管理平台的湖仓一体和向量数据库进行业务数据采集/清洗/预处理和向量数据检索；采用AI训推平台支撑AI模型的开发和部署全链路。

- 通过算力调度、智能运维能力，帮助医疗机构提升对智能算力资源的使用率，降低智算基础设施和智能应用的运维难度。
- 采用体系化的数据保护和隐私计算等安全合规技术，确保医疗数据生成、存储和使用全流程的安全合规。
- **场景化服务：**医疗行业的智能化对于AI Infra在模型训练/微调、在线/离线推理、多模态模型融合和模型准确率优化等场景的应用有着较为明确的需求；尤其在模型准确率优化方面，通过准确率的提升促进在特定医疗场景对人工诊疗的辅助和替代，提升患者的诊疗效率。同时，模型训练/微调的加速和推理能力的增强，能够帮助医疗机构适配多种智能化场景，提升智能应用的业务扩展能力。

03

腾讯云智算赋能千行百业： 行业智能化落地实践

通过对各行各业的AI发展趋势洞察发现，当前针对各类AI应用发展而来的AI Infra，天然具备云平台的大规模算力、强扩展能力、高安全性，以及运营管理能力。在此基础上，逐渐演化出针对AI模型高效开发和AI应用持续交付运维加速的AI Infra，从分布式云、智算基础设施、智算技术平台、安全合规、调度与管理五个维度为全流程AI提供专属的平台能力和技术特性，帮助行业企业实现AI在各类业务场景的深度应用。

腾讯云智算是AI原生应用驱动的、下一代基于云平台的AI Infra。通过打造算存网数一体的高性能智算底座，集结高性能计算集群HCC、高性能推理实例、智能高性能网络IHN、高性能存储、训推加速套件TACO、私有化智算套件、向量数据库、AI容器等AI基础设施产品，输出性能领先、多芯兼容、部署灵活的AI Infra产品技术能力，为交通出行、金融保险、工业制造、教育培训、具身智能等诸多行业提供高效、全面的云智算解决方案，帮助企业加速释放AI生产力。

3.1 交通出行

地平线：基于vRDMA加速网络技术，加速训练集群规模化落地

背景

地平线通过自研训练平台统一调度分配任务，支持感知、预测、规划等全链路自动驾驶模型训练；企业需求持续增长，新增千卡级GPU训练集群需求，项目时间紧，需快速支持；业务多云环境接入，需要提供有竞争力的产品方案。

腾讯云高性能计算集群以高性能云服务为节点，运用vRDMA自研加速网络技术，助力地平线训练集群规模化落地。


需求与挑战

- 业务增长，GPU需求规模大，需要寻求腾讯云算力资源快速适配上量接入
- 在多机训练场景下，机间通信使用VPC网络训练扩展损耗较高
- 业务场景RDMA带宽需求追求高性价比

解决方案

腾讯云基于智驾场景中企业重点关注的数据处理、智驾模型训练等需求，进行产品与方案实施：在公有云/自驾云专区，最新代次GPU算力+vRDMA机型通过搭载最新代次AMD CPU，以及基于VPC网络的自研vRDMA技术，实现业务应用零成本适配；结合腾讯云内部自研优势经验积累，优化通信路径以及OS内核，千卡集群线性扩展比最高可达92%，可满足大量路采数据的清洗、识别和标注等高效数据处理需求；可满足智驾训推场景中高精度和大显存GPU算力、大规模GPU算力集群并行加速能力等需求。

图3 腾讯云-地平线自动驾驶训练方案架构图



来源:腾讯云, 2025

效果与收益

- 通过200Gbps vRDMA带宽，满足业务带宽需求，实现提效降本；
- 在原有的VPC网络基础上即可实现vRDMA，无需额外硬件建设成本，业务无需额外付费即可享受RDMA加速网络性能；
- 相比业务本地训练集群，训练性能提升5%；相比VPC网络，训练性能提升25%以上。

交通出行

货拉拉：高性能存储加速数据处理，助力AI应用业务落地

背景

货拉拉是从事同城/跨城货运、企业版物流服务、搬家、零担、跑腿、冷运、汽车租赁及车后市场服务的互联网物流商城。通过共享模式整合社会运力资源，完成海量运力储备，并依托移动互联、大数据和人工智能技术，搭建“方便、科技、可靠”的货运平台，实现多种车型的即时智能调度，为个人、商户及企业提供高效的物流解决方案。

腾讯云大数据存储解决方案凭借「智能一体化、安全稳定、极致性能」的产品技术能力，满足客户超大规模数据湖存储。在保障稳定性的同时，提升读写性能，缩短上层离线任务执行耗时，满足下层业务分析实效性要求。

需求与挑战

- 超大规模存储稳定性：货拉拉业务规模已达超亿级文件数量规模。在此规模下，数据湖存储需要保障数据可靠性满足不丢失需求，同时业务高可用，满足任务执行期间业务不受损。
- 时延敏感型任务性能保障：大数据业务涵盖离线计算、流处理、OLAP等多种作业类型，上层支撑多种时延敏感型分析任务，均对任务时效性有较高要求。
- 丰富的运维审计能力：货拉拉上层数据管控体系，依赖存储提供丰富的运维审计能力，通过日志、清单的连表分析进行冷热数据精细化运维。
- 更优的成本控制：在数据存储和管理的同时，企业还必须控制成本，提高运营效率。存储系统需要提供高效的数据管理和存储能力，同时保持成本的可控性。

解决方案

货拉拉基于腾讯云Data Platform数据平台解决方案构建公有云大数据平台，COS作为数据统一存储底座，结合元数据加速器搭建离线数仓，热数据缓存在数据加速器的高性能存储集群中，上层自建大数据集群。

- 资源隔离与带宽优化（对象存储COS分桶策略）业务分桶隔离，将AI模型训练、数仓、报表服务等业务数据拆分至独立COS存储桶，实现带宽隔离。
- 对象存储COS作为海量数据的统一存储池能够提供安全稳定的数据存储能力，在大幅提升系统可用性、可靠性及性能的同时大幅降低存储成本。
- 分布式文件系统GooseFS提供元数据的数据缓存加速服务，通过协议兼容特性，提供百GB级别带宽、十万级QPS以及毫秒级延迟的访问性能。

效果与收益

- 单模型训练带宽下降8%，消除AI任务对离线链路的干扰；
- 40PB+大数据搬迁1年多0故障；
- 货运报表产出提前40min，任务提速10%。

腾讯云也将与货拉拉继续深化合作，双方将在数据湖存储、智能存储等方面深度协同，通过数据加速器提升计算效率，降低COS访问延迟。

交通出行

一汽丰田：构建坚实的安全底座，驱动AI大模型赋能业务创新与降本增效

背景与挑战

一汽丰田作为国内头部合资汽车品牌，在车联网、汽车营销等车企重要业务领域有深厚的积累，是汽车行业数字化领域的推动者。

自2024年起，一汽丰田携手腾讯，在汽车企业安全建设方向上进行了深度合作，力求确保重要业务系统、重要数据信息的安全性。2025年起，一汽丰田携手腾讯打造了大模型智能客服应答服务，为企业降本增效，优化用户体验。

企业发展安全是基石，守好网络安全底线、保障数据安全与合规是关键。AI技术的突破正驱动汽车产业全面进化，企业需加速掌握革新技术，不断提升用户体验。

解决方案

- 构建数智化安全平台：在整体汽车云安全建设上，一汽丰田充分考虑到混合云、去中心化办公模式带来的治理复杂度，因此结合腾讯安全能力，构建了一套云端融合的数智化平台。平台具备多种能力，能够服务于基础安全、数据安全、安全运营建设，为护航重要业务系统起到了关键性作用。
- 打造大模型知识引擎：在一汽丰田APP/小程序/官网等终端提供AI智能客服服务，提供售前、售中和售后问题的查询，包括用车指引、故障查询、服务预约等。

效果与收益

- 在安全领域，一汽丰田数智化安全平台已经接入多云、多办公环境的安全告警信息，能够做到安全事件RTD（平均检测到响应时间） ≤ 2 小时。平台已支持公司内数十个业务系统的数据分类分级，并通过免改造的方式落实了数十个库表的加密、脱敏策略。
- 在AI智能客服领域，自2025年1月接入腾讯大模型并上线以来，月咨询量达到17000条，拦截率从此前的37%提升至84%，其中有效拦截率准确率达到73%。

交通出行

某头部新势力车企：突破数据瓶颈，加速智驾训推效率

背景与挑战

某全球领先的智能电动汽车品牌在推进其汽车辅助驾驶研发过程中，面临三大关键挑战：首先，需要处理来自量产车与采集车上传的百PB级数据，但缺乏自建存储运维能力；其次，现有业务流程存在效率瓶颈，尤其在模型训练环节，海量小文件导致的IO性能问题严重拉低GPU集群利用率；此外，该企业亟需构建能够同时支持HDFS与POSIX多协议访问、并满足高性能训练加速需求的统一存储架构，以消除多计算平台之间的数据壁垒。

解决方案

海量数据存储平台

COS存储服务提供弹性EB级存储空间与Tbps级上行带宽（支撑百万车辆并发上传），以统一存储池承接原始数据、预处理结果及训练数据集。

全环节加速引擎


- 数据预处理：通过高性能缓存服务GooseFS-Cache自动缓存量产车上传热数据，消除存储瓶颈，提升预处理效率；
- 模型训练：采用分布式高性能文件系统GooseFS-X，解决视频抽帧生成的海量小文件IO压力，提升训练性能；同时，模型训练过程中的Checkpoint实现秒级高并发写入GooseFS-X；

- 仿真验证：通过GooseFS-Lite实现仿真平台以POSIX协议直接访问COS原始数据，加速仿真迭代。

业务数据流闭环

从数据上传触发预处理任务，训练数据集按策略预热至GooseFS存储平台，实现"采集→处理→训练→仿真"业务数据流闭环。

图4 企业业务数据流闭环示意图



来源：腾讯云，2025

效果与收益

- COS百PB级存储成本降低40%，Tbps级带宽满足百万车辆实时数据注入，解决数据快速增长需求。
- GooseFS-Cache作为高性能存储缓存服务，通过HDFS、POSIX，对接数据预处理平台，90%+以上数据命中在Cache，数据预处理性能提高30%。
- 基于GooseFS-X和COS存储服务的数据流动能力，各种训练业务均可基于不同的使用策略加载或沉降训练集数据，大幅提升了训练存储的使用效率，同时降低整体存储方案成本。

3.2 工业制造

燧原科技：

打造国产异构超大规模智算云平台，提供高性能AI算力资源和全栈服务

背景与挑战

面临国产GPU生态适配与算力资源协同调度的双重挑战，燧原科技通过多方联合测试，实现技术突破，解决燧原国产化算力卡与新一代智算中心系统的兼容难题。同时，为协调新一代计算、存储、异构算力资源的高效联动，燧原科技依托腾讯专有云智算套件解决方案，实现算力智能调度与实时监控，构建资源优化配置体系，确保新一代智算中心稳定运行。

解决方案

燧原科技以腾讯专有云智算套件解决方案为基座，结合国产算力卡，于国家“东数西算”战略的核心节点——庆阳，构建全新一代国产GPU智算数据中心。整体架构将以硬件基础设施、软件平台与服务为核心建设内容。其中，硬件基础设施包括通用算力资源池、智能应用算力资源池、AI算力适配系统、通用计算设备、网络设备、存储设备等硬件资源；软件平台与服务是以AI云服务平台、AI大模型应用服务作为应用支撑，并按照信息安全等保2.0第三级防护要求，建设智算中心的端到端防护的云原生安全防护体系。

效果与收益

本项目以“超大规模云平台+国产化GPU+智算中心”的建设模式，响应国家东数西算的战略目标，不仅解决了一部分智算资源的基础诉求，为行业客户提供了高性能的解决方案，也为同行业其他智算中心的建设起到示范作用。

工业制造

某知名手机厂商：优化大模型部署架构，提升训练与分发效能

背景

某全球领先智能终端提供商凭借广泛覆盖的产品生态，已积累了海量用户与活跃度，但在AI场景下，庞大的数据量及超大DAU规模为存储系统带来双重挑战：一方面，训练任务要求存储系统持续提供高QPS（每秒查询率）和高带宽支持实时数据读取；另一方面，部署环节中出现的单文件热点问题，进一步加剧了系统压力。这些问题严重制约了AI业务的整体效率，亟需系统性的解决方案。与此同时，该企业全球业务迅猛增长，也对GPU算力资源的调度效率与集群稳定性提出了更高的要求。

需求

- 训练环节需支持高QPS和高带宽数据读取，将样本数据拉取至训练集群；
- 分发环节需要解决单文件热点问题，支持多客户端节点并发拉取模型文件；
- 全链路需要低延迟，提升IO效率，避免计算资源闲置浪费；
- AI业务场景对服务器稳定性和网络质量有较高要求；
- 为支持AI助手等业务的快速增长，推理算力需要具备全球多地域双AZ供应能力，并支持快速扩容等要求。

解决方案

该企业基于腾讯云Data Platform构建大模型服务，得益于GooseFS存储平台近客户端部署架构，在训练大规模AI模型时能够提供更高的读QPS及更低的时延，大幅缩短训练任务耗时，规避由于COS频控等限制带来的任务失败问题。同时，GooseFS通过将模型文件多副本打散至缓存层，能够提供更高的单热点并发QPS，充分利用全闪存介质提供的更高吞吐及更低时延，大幅提升分发效率。

腾讯云星海自研AI服务器针对AI场景定制优化和智能巡检，提高服务的稳定性，千卡单日故障率仅0.16。


凭借着丰富的GPU算力实例规格、海内外多地域布局、灵活便捷的使用体验及千卡级推理集群稳定运行等特性，该企业实现了智能终端AI助手推理业务的高速增长及出海布局。

依托全球50+加速节点随时随地就近接入，实现全球应用加速。

效果与收益

- 通过部署Data Platform进行大模型分发，该企业单链接速度达300 MBps，较未部署前带宽提升了10倍；
- GPU节点提升1.5倍的情况下，分发时间压缩到原有的三分之一，大幅提升了分发效率；
- 服务稳定性相比优化前提升了57%；
- 访问更顺畅，网络丢包和抖动均降低了99%。

图5 大模型部署示意图



来源：腾讯云，2025

3.3 教育培训

作业帮：拥抱AI，实现业务提效

背景

作业帮教育科技（北京）有限公司成立于2015年，以“科技为人、成就非凡”为企业使命，依托“科技+教育”双引擎优势，深入布局学习工具产品、智能硬件等领域，让人工智能技术于在线教育场景中真正落地。

需求与挑战

作业帮旨在通过AI为用户带来更好的学习和使用体验，其中包括智能搜题、作业批改、智能问答、AI直播课程等，均面临算力方面的需求和挑战，需要针对不同场景提供最具性价比的GPU服务器。

在推理服务部署使用中存在多个容器间共享GPU卡的场景，从而实现提高GPU使用率、降低成本的目的。需要在共享时尽量保证业务性能与资源不受干扰。

在直播场景中，AI的应用面临高并发和低延迟的挑战，需要同时支持3000+名学生在线生图，出图确保15秒以内，需要实现极致的弹性伸缩。

作业帮除了在积极布局基于大模型相关的业务，也在同步提升自身业务的服务效能，从而挖掘新的业务增长点。在实际落地过程中，客户业务在业务安全方向做RAG服务，因大模型存在的幻觉问题，需要借助向量数据库来提升召回率，从而达到业务上线的标准。

解决方案

通过TKE纳管多种类型的GPU服务器，结合GPU共享技术（qGPU）实现精准的GPU资源调度能力，支持作业帮模型训练和推理需求，满足拍搜、AI问答等业务降本诉求、提高了GPU使用率。

结合Serverless服务及TACO-DiT推理加速技术，提供弹性的AI接口调用能力，满足客户业务个性化API调用需求，保障高峰弹性资源供给，达到业务推理SLO目标，出图速度达到5s左右。

作业帮在初步调研测试后，使用腾讯云向量数据库作为大模型的外挂知识库，以向量数据支持的语义级别检索方式作为检索核心能力，使用腾讯云向量数据库自带的Embedding功能，使得业务接入效率提升80%，客户成本降低90%。

效果与收益

- ◎ 向量检索效能实证：向量数据库上线后，经作业帮实测发现仅靠向量检索可以覆盖95%场景，且效果好于关键字检索方案；
- ◎ 告警处理效率提升：有效告警的识别率显著提高，告警噪音占比大幅降低，研判盲区缩小，低危告警中的真实威胁得以被快速发现；
- ◎ 响应速度加快：高危告警的处置周期从2小时大幅缩短，人工响应准确率提升至95%以上，减少了攻击窗口期和二次事件的发生；
- ◎ 知识沉淀与复用：统一知识库的构建和自动化迭代体系的建立，使推理逻辑黑盒问题得到有效解决，知识复用率显著提升；
- ◎ 满足独享和隔离性需求：结合TKE平台能力，支持业务在离线混布；
- ◎ 混合部署实现弹性扩容：资源利用率提升40%，成本降低30%。

教育培训

考试宝：基于向量数据库构建“数据枢纽”，打造高性能海量职业技能试题检索服务

背景

上海巨闲网络科技有限公司成立于2019年，是一家有互联网基因的科技创新企业。截至2025年6月，考试宝平台上的试题量已经超过60亿道，覆盖了10000多个职业类别，是覆盖全品类的职业教育考试学习产品，用户总量也突破了8000万。

需求与挑战

- ◎ 平台在职业教育领域已积累试题达60亿道，形成庞大的教育资源库，然而这一数据规模导致现有检索系统面临效率瓶颈，很难满足用户对个性化学习、实时反馈和高准确率的迫切需求；
- ◎ 依赖传统人工处理的海量数据运营模式，具有双重缺陷：成本极高的同时难以实现可持续运营。

解决方案

基于模型Embedding与向量检索的技术路线，相较于传统人工处理模式，在运营效率、数据准确性和成本控制上均展示出显著优势。

考试宝基于腾讯云向量数据库内置的向量模型和检索能力，实现对亿量级试题的高效聚类打标，有效剔除无效和低质内容，充分释放海量题库的数据价值。

相比于传统数据库，腾讯云数据库采用先进算法，大幅提升相似性搜索效率；在处理海量数据的速度上，更展现出卓越的性能表现。

效果与收益

基于腾讯云向量数据库的技术赋能，平台在效率、成本、体验三个维度实现全面跃升：试题聚类的准确率从原来的50%提升到了95%；检索吞吐能力是行业平均水平的10倍，响应延迟则降到了毫秒级；人工标注成本明显下降。

这种技术革新直接带动了业务增长——用户的付费率提升了50%以上，使用效率提高了20%，覆盖用户超过8000万、职业类别超过1万个。

3.4 泛互联网和IT服务

心言集团：持续优化技术架构，用AIGC重构泛心理行业

背景

心言集团于2011年在北京成立，秉承“以科技服务心灵”的发展理念，经过十余年踔厉奋发，已逐步发展为AI泛心理与情感陪伴领域的创新引领者。2013年，集团正式推出明星产品——测测App（Cece App），为用户提供基于科学量化而又温暖有趣的AI情感陪伴产品及服务，致力于让广大用户“遇见更好的自己”。截至2025年6月，测测注册用户近5200万，签约咨询师超过26000名。

需求与挑战

日益增长的用户需求和AIGC在泛心理服务各个场景的深入应用，以及心言集团本身正在推进的全球化进程，让测测App在技术架构和稳定运行上面临着新的挑战。

- 面对高速增长的用户需求、产品服务的快速迭代以及业务的全球化拓展，测测App亟需一种能够稳定、灵活、按需提供的云计算资源和服务解决方案，以确保高效利用并避免资源浪费和线路中断风险；
- 大模型训练和推理业务场景，对GPU算力的需求呈指数级增长，因此需要解决自研情感大模型“心元”训练和推理需要的大规模GPU算力问题等。

解决方案

腾讯云凭借全栈的云产品能力和丰富的客户服务经验为心言集团制定了针对性的解决方案，兼顾用云成本和效率：

- 针对用云成本和效率兼顾的问题，腾讯云通过TKE容器服务解决因需求快速变化带来的部署问题，通过TKE智能调度算法和qGPU技术助力客户提升资源利用率和降低成本。
- 为解决心言集团自研情感大模型“心元”对于GPU算力的需求缺口和成本压力，腾讯云提供了GPU资源共享技术和GPU算力在离线混部能力。
- 依托腾讯云星脉网络，提升数据传输效率，助力客户应对高并发的业务场景。

效果与收益

- 通过TKE容器服务，测测App可在几分钟内完成部署，彻底解决业务需求快速迭代带来的部署挑战。相较于之前虚拟机部署方案，部署速度提升约50%。通过TKE智能调度算法和qGPU技术，资源利用率提升至90%以上，同时平均成本节约达20%，可轻松应对千万级用户的高并发访问。
- 在算力支撑方面，基于腾讯云异构计算产品有效满足测测持续增长的AI推理算力需求，实现训练成本的降低，提高训练速度。
- 基于腾讯云星脉网络提升数据传输效率40%，助力测测App实现如语音咨询、心理测评、社区互动交流等核心业务的稳定运行，支持千万用户高并发访问。

泛互联网和IT服务

尚航科技：依托专有云智算套件解决方案，助力尚云SunClouds打造一云多算高效能智算平台

需求与挑战

- 企业缺乏云计算技术积累和运维经验，IT系统难以实现平台化运营，无法有效驱动业务增长；
- 企业在智算业务版图拓展中，面临组网、存储、GPU加速、平台运营能力(计量/计费/账户体系/租户隔离等)等维度的短板；
- 传统IDC架构无法支撑向“AIDC+云”的增值转型需求。

解决方案

尚航与腾讯合作，基于腾讯专有云智算套件解决方案，获得IaaS/PaaS服务，包括高性能计算集群HCC、虚拟化和容器、分布式存储、并行文件存储、VPC网络、专线、NAT、企业级数据库和云原生安全及各类开箱即用云服务。云管平台对接尚云Portal形成产品运营、用户运营、计费运营的大型一云多算平台。

效果与收益

● 借助腾讯专有云智算套件解决方案拓展智算业务版图

- 尚航采用腾讯专有云智算套件解决方案作为数字化底座，进军行业云市场，提供私有云、数据应用和智能化服务。
- 采用腾讯专有云智算套件解决方案，尚云SunClouds算力平台支持多种计算和存储需求，提供一站式云服务。首期在江苏无锡上线，未来将扩展至全球，构建高可靠性的智能算力云服务平台。
- 技术需求上涵盖GPU算力虚拟化与容器化、大容量存储与高性能并行文件存储、InfiniBand组网、平台运营能力(计量/计费/账户体系/租户隔离等)。

● 助力“AIDC+云”驱动下的创新发展

- “AIDC+云”驱动下的创新：在一云多算的大背景下，尚航科技通过创新和变革，保持行业领先地位。公司利用云技术降低迭代成本，快速试错，聚焦于智算和XaaS服务。结合腾讯云的技术优势，以“AIDC+云”作为双向驱动业务模式，实现高质量快速发展。
- 市场化发展：尚航科技通过与IT团队、云技术提供商及咨询实施伙伴的紧密合作，创新商业模式，建立符合行业云平台的服务和运营体系，助力行业云市场化经营在不确定性中实现突破。

● 助力无锡算力公共服务平台完成异地算力调度交易

无锡市首笔异地算力调度交易正式成交。尚航科技携市内外总计200P智能算力加入“无锡新型城市算力中心”普惠算力服务体系。

- 算力资源利用率提升：利用统一的纳管算力资源平台，对算力资源灵活混布，极致压榨GPU算力资源。
- 业务效率提升：统一纳管平台后，加速算力资源调度和分配，显著提升业务效率。
- 降低资源成本：算力资源的按需分配和调度，降低资源使用成本。

泛互联网和IT服务

元石科技：AIGC数据湖实现跨国数据传输，实时合规与存算协同

背景

元石科技于2022年创立，专注于AIGC领域，主要从事大规模模型的训练与应用，其业务涵盖文本生成和图像生成，需要处理海量数据，并依赖强大的GPU计算能力和高效稳定的大规模存储解决方案以保证模型训练和生成的高效性和稳定性。

需求

- 提升数据获取能力，支持快速获取海外数据集，并高效回传国内；
- 提升数据清洗效率，支持Spark/Hive等组件对存储桶数据高效处理；
- 支持高IO的模型训练和推理，训练阶段需实现checkpoint快速写入，推理阶段需快速加载模型文件；
- 提高AIGC内容审核效率并满足合规要求。

挑战

- 算力短缺：需要云厂商提供弹性GPU算力资源，以满足不断增长的计算需求；
- 存储瓶颈：数据增长迅速，现有存储资源不足，且存储性能无法匹配GPU算力影响训练效率；
- 合规风险：AIGC生成内容需满足监管要求，面临合规审核的挑战。


解决方案

- 通过数据迁移服务平台MSP快速拉取国内外的训练素材；
- 在数据清洗阶段，COS存储服务提供的融合加速桶方案采用原生HDFS协议，满足Spark/Hive等大数据组件处理；在模型训练和推理阶段，GooseFS-X/CFS Turbo高性能并行文件存储满足模型文件快速加载显存，且可以快速异地拉取模型文件，让COS存储桶之间数据自由流动；
- 在数据管理阶段，借力数据万象对生成内容进行处理和审核。

效果与收益

- 效率提升：数据爬取效率提升100倍，数据清洗效率提升5-10倍，模型加载时间提升至分钟级；
- 成本优化：高性能文件存储成本降低50%，进一步降低推理存力和算力成本；
- 业务保障：合规拦截率从80%提升到95%+，降低合规风险。

图6 AIGC全链路存储方案示意图



来源：腾讯云, 2025

3.5 具身智能

某科研单位：构建人工智能训练平台，打造前沿开放统一具身智能平台底座

背景

某研究院人机交互与仿真测试平台，聚焦于人居环境具身智能领域的研究，以推动相关技术的创新与应用。该院根据高标准推进重点实验室建设有关计划，突破具身智能感知、移动、决策、交互等关键核心技术，打造前沿开放的统一具身智能平台底座。

机器人的数据采集极为复杂，数据采集的方式和来源具有多样性，因此对多模态的数据存储支持要求很高；每一个机器人、包括每一个型号的机器人数据都是独立的，因此，每一个机器人的数据采集无法互相复用，因而在数据存储和训练方面产生高成本。这是当前机器人行业面临的主要痛点。

挑战

- 需要整合语音、视觉、触觉等多源传感数据，实现海量多模态数据存储，并保障高可靠性与低成本；
- 满足算力与实时性需求需要超算力支持，现有硬件环境难以满足低延迟与实时数据同步要求，制约了平台测试效率；
- 通过平台确保高性能训练：训练任务需要高性能读写IO，保障训练时效。

解决方案

依托腾讯云TI-ONE平台纳管GPU算力集群，提供从数据准备、模型训练、模型评测到模型服务部署的全流程支持，用于具身智能大模型仿真训练；使用腾讯云Data Platform方案，提供海量可靠存储和低成本、高性能文件访问服务；配套采用腾讯云数据库、负载均衡、安全等产品服务，确保数据加密、权限控制及合规性问题。


效果与收益

- 满足自身业务需求，帮助实现与构建了一套覆盖基础设施、算力调度、存储优化及安全合规的全栈解决方案。

- Data Platform端到端的解决方案满足海量多模态数据的存储需求，按需扩容和缩容，支持数据在COS和GooseFS存储平台之间自由流动，实现高可靠、低成本的海量存储。基于GooseFS-X实现单客户端40Gbps吞吐，亚毫秒时延，满足训练性能诉求；通过GooseFS-Cache利用GPU上的NVMe盘，构建分布式缓存系统，在保障读性能的前提下有效降低成本。
- 统一管理高效检索：基于Metainsight进行统一数据管理，高效筛选适用数据，减少训练资源浪费，训练任务综合效率成倍提升。
- 提供统一算力管理平台，便捷管理和使用算力资源池，结合容器化调度（TKE）与自动化运维，实现资源按需分配和细粒度管理，训练效率提升200%。

该项目对打造统一的具身智能开放平台、扶持孵化具身智能产业发展至关重要，推动人形机器人技术从实验室迈向产业化。

图7 人工智能训练平台架构图



来源：腾讯云，2025

3.6 医疗行业

智诊科技“好伴AI”：以智算之力，构建普惠医疗新范式

背景

智诊科技专注于医疗领域的人工智能技术研发与应用，公司核心团队汇聚了计算机科学、临床医学等多领域人才，自主研发千亿参数多模态医疗大模型WiseDiag，面向用户推出“好伴AI”等AI应用产品，提供智能诊断、报告解读、健康管理等服务。

挑战

- AI传统工具局限性：现有医疗AI多为即时问答模式，缺乏对用户健康状况的长期记忆与动态理解，难以支撑如慢病患者连续跟踪等长期、个性化的健康管理需求。
- 优质医疗资源稀缺：顶尖专家资源高度集中，基层医疗服务能力有限，大众对即时、专业、可信赖的健康管理需求日益增长。
- 技术与算力瓶颈：自研的千亿级跨模态医学大模型WiseDiag，其训练、微调与大规模推理应用，对算力的稳定性、弹性与效能提出了极致要求。

解决方案

智诊科技与腾讯云进行战略合作，依托腾讯云强大的智算平台与稳定的云基础设施，成功训练并高效部署了WiseDiag大模型。在此基础上，公司打造了AI健康管理应用“好伴AI”，通过构建“医生数字分身”，为公立医院和基层医疗机构提供7x24小时的智能健康咨询、慢病管理与风险预警服务，形成“AI-基层-专科”三级协同的新模式。

智诊科技充分发挥了腾讯云GPU在训练和推理集群上的性能优势和产品算力优化能力，相较于友商同量级产品具备显著优势，有力支持了“好伴AI”小程序C端用户的高并发访问需求。基于腾讯云自研的星脉网络，集群式多机互联和数据传输效率得到极大提升。同时，采用高性能并行文件存储CFS Turbo，将医疗训练样本、训练检查点和最终模型文件保存在统一存储中，贯穿样本准备、模型训练、模型推理的全流程。业务峰值吞吐达10GB/s，大幅提升了训练与推理效率，加速了千亿参数跨模态医疗大模型WiseDiag的迭代与上线。

效果与收益

- **核心引擎性能卓越：**基于腾讯云强大的智算能力训练的WiseDiag大模型，在MedBench全球中文医疗AI评测榜单中，多次综合排名位列第一，展现了超越通用大模型的专业级医学理解与推理能力。
- **创新打造“专家AI分身”：**不止于通用问答。通过深度学习专家个体的论文、临床手记、问诊视频等知识，并结合腾讯云的高性能计算，为超过500名顶尖专家成功打造了个性化的“数字分身”，将稀缺的专家智慧规模化、普惠化。
- **实现从“被动问答”到“主动式关怀”：**依托创新的长期记忆系统，好伴AI能动态理解用户健康状况。它不再是被动等待提问的工具，而是能基于用户的健康档案和潜在风险，在关键时刻主动发起健康提醒、随访与风险预警，成为真正的“健康行为教练”。
- **专业高效的复杂医学报告解读：**凭借强大的多模态能力和医学编码模型，“好伴AI”能够深度解读体检报告、化验单等复杂医疗文档，精准提取关键指标，再现医生诊断思维，为用户提供专业、易懂的解读与建议。
- **构建AI赋能的大健康内容平台：**该方案实现“好伴AI”从工具升级为生态平台，连接健康内容的供给方（专家、达人）与需求方（用户）。AI不仅是服务引擎，更是内容创作、分发和互动的赋能者，助力构建全新的健康服务生态。
- **创造显著社会价值：**有效降低了居民获取优质健康服务的门槛，将医疗服务从“治疗（Cure）”向“关怀（Care）”转变，真正解决了基层健康管理的“最后一公里”难题。

智诊科技创始人宋宁博士评价到：“与腾讯云的战略合作至关重要。腾讯云稳定、高性能的智算能力，为我们WiseDiag大模型的训练和推理提供了坚实的算力基座。这使得我们能将顶尖专家的智慧与经验高效地转化为普惠的AI服务，让亿万家庭享受到便捷、可靠的健康管理，共同推进全民健康事业迈入新时代。”

医疗行业

德适生物iMedImage™：引领全球医学影像行业迈入智能化时代

背景

iMedImage™是德适生物自主研发的千亿参数规模的通用型医学影像基座模型，打破传统模型开发普遍面临的高门槛、长周期、低效率等难题，可实现基于少量样本快速构建专科模型，推动全球医学影像行业迈入智能化时代。

需求与挑战

传统医学影像领域长期面临多重挑战，如多模态数据标准化程度低，导致数据整合及应用困难；经验丰富的影像科医生短缺及图像解读的主观性，限制诊断效率；传统AI泛化能力弱、可复用性低、研发及临床周期长等。更丰富的临床医学影像场景覆盖，更具扩展性的模型训推能力，成为iMedImage™医学影像大规模基座模型的关键技术点。

解决方案

腾讯云与德适生物合作，通过提供高性能GPU算力与弹性资源调度支持，显著提升了模型训练与推理效率，加速科研场景中的模型开发与应用落地。德适生物基于自主研发的iMedImage™基座模型，提供给客户iMed MaaS医学AI平台及存算训推一体化解决方案。作为全球领先、千万亿参数规模的通用型医学影像AI基座模型，iMedImage™充分借助其多模态支持、多病种兼容、低成本迁移、高基准性能等领先优势，推动全球医学影像行业加速智能化进程。

腾讯云基于高性能应用服务HAI的即插即用算力，为德适生物提供一键部署AI大模型能力，省去算力机型选型、环境部署、模型权重下载等繁琐的上线流程，大幅提升模型应用的开发生产效率；推理集群能力大幅提升模型推理效率、推理吞吐性能翻倍提升；通过腾讯云高性能计算集群HCC，帮助德适生物原生实现集群内高速通信，提升集群算力使用率，高效管理计算资源，并结合共享文件存储CFS实现多节点同一个项目只需同一套代码，极大提升训练及推理大规模节点的并行效率。

效果与收益

iMedImage™基座模型支持19种医学影像模态（如染色体、CT、MRI、超声、病理等），并覆盖超过90%的临床医学影像场景，帮助医疗机构在影像数据上实现自动识别、辅助诊断、风险预测、科研建模等功能，广泛适用于染色体分析、病灶辅助识别、产科风险预测、慢病管理等场景。通过腾讯云高性能计算集群HCC方案部署，大模型训练资源利用率提升30%，同时降低了成本投入；HAI推理集群能力大规模扩容整体服务拉起时间从30分钟缩短至2分钟，模型推理效率、推理吞吐性能翻倍提升，通过腾讯云端加云双驱动产品部署方式，使得iMedImage™的可迁移性、可扩展性及泛化能力更灵活地应用于客户的大模型训练和推理场景，让医疗工作者“用自有数据自主训练AI”，显著降低科研成本及时间，提高从科研到临床应用的效率，为AI医疗健康提供创新解决方案。

关于腾讯云智算

腾讯云智算 算存网数一体的高性能智算底座，助力产业AI应用加速

腾讯云智算凭借性能领先、多芯兼容、部署灵活的产品技术能力，为产业提供高效、全面的云智算解决方案，突破算力瓶颈，加速释放AI生产力。集结高性能计算集群HCC、高性能推理实例、智能高性能网络IHN、高性能存储、计算加速套件TACO、私有化智算套件TICI、向量数据库和AI容器等自研AI基础设施，打破计算、存储、网络的“木桶效应”，适用于公有云和私有化环境。2025年腾讯云再次围绕云智算全景能力升级，加速Agent落地，面向推理需求和Agent的爆发趋势，助力Agent从“实验室”进入生产场景。围绕AI推理加速，打造从成本到性能再到用户体验的最优解。通过AI Infra，在模型启动、双机吞吐、元宝解码速度上实现业界领先；发布Agent Infra解决方案Agent Runtime，提供运行引擎、沙箱、网关、上下文、可观测五大能力，其中沙箱启停速度业界领先；发发布腾讯云专家服务智能体“Cloud Mate”，在架构治理、风险拦截、排障等方面大幅提效，打造能“主动服务”的云。

图8 腾讯云智算全景图



来源：腾讯云，2025

Agent Infra解决方案Agent Runtime

当Agent拥有高度自主性与执行能力后，高度依赖外部工具（浏览器、PC应用、Code Interpreter、MCP等）时，需保障工具的注册发现、调用的稳定性、执行轨迹可追溯，多工具、多会话、多步骤的执行过程也增加了调试难度。此外，Agent过高的自主执行权限可能造成不可逆的破坏（如批量删除业务数据），跨系统调用的认证复杂性等。针对Agent工程化的痛点，腾讯云智算持续打磨调度能力，演进成为更贴近Agent的AI Infra，帮助Agentic AI从“实验室”走向“生产级”。

新一代企业级智能体基础设施引擎腾讯云AgentRuntime云沙箱：为企业在生产环境中构建、部署、运行大规模AI Agent应用提供极简运维、全链路安全的AI Infra。AgentRun基于会话隔离、秒级启动、超高并发的Serverless运行时Cube，为编码助手、GUI-Agent、自动化测试、Agent RL等场景提供安全、弹性、低延迟的运行环境，支持浏览器、PC、Code等多类型沙箱，实现工具安全接入与环境级防护。

腾讯云AgentRuntime智能统一可观测平台深度融合数据分析与AI能力构建“数据智能中枢”，提供端到端可观测及AIOps支撑。其核心能力包括多模态数据统一接入（日志/指标/Tracing，兼容MCP及第三方数据源）、基于垂直领域精调大模型的自动排障与根因推理，以及动态决策引擎驱动的实时异常检测与修复。独特优势涵盖领域精调模型、全栈数据融合、零门槛自然语言交互，实现了“预警-排障-优化”全生命周期的企业级闭环。CLS已助力汽车、出行、零售、房地产服务等行业实现运维从被动响应到主动预防的升级，为AI Infra提供智能可观测底座。

腾讯云AgentRuntime全域上下文AgentContext是TDAI智能体基础设施的核心数据基座，由Memory（记忆管理）、DeepSearch（深度检索）和Catalog（数据目录）三大模块协同构建，旨在为智能体提供企业私域记忆和数据中枢，构建企业专属的智能体应用。Memory是赋予Agent记忆能力的核心系统，支持存储、检索并管理智能体记忆，可以让Agent表现出更强上下文理解力和个性化服务能力。DeepSearch是以自然语言作为查询输入、具备问题理解和评估反馈能力的搜索引擎，满足智能体的语义/数据检索需求。Catalog是面向多源数据的元数据管理平台，助力构建智能体的统一数据底座。

腾讯云AgentRuntimeAgent网关作为企业AI应用的核心枢纽，具备多维度核心能力：一方面，通过多模型代理、模型全链路监控等实现智能治理，并依托多API Key隔离、RBAC细粒度权限控制等能力，保障AI应用安全合规。另一方面，网关支持MCP、SSE等多协议，实现传统服务与AI

流式场景的无缝衔接，提供统一、可追溯的接入与基础治理能力，助力企业历史资产与新 AI 能力高效融合。

AI Infra高性能软件

腾讯云高性能计算集群HCC（Tencent Cloud Hyper Computing Cluster），软硬自研一体，集结了国内外前沿芯片，搭载腾讯自研3.2T RDMA 星脉网络，GooseFS/CFS Turbo超高性能存储，打破计算、网络、存储性能“木桶”效应，实例丰富度全球领先，坚固性能与性价比，充沛算力随取随用。稳定性、数据读写效率、集群通信时长等关键性能业内领先，机器从上架到开始训练可以做到只需1天。覆盖大模型训练与推理、智能驾驶、互联网应用、广告搜索推荐、图像处理、具身智能、科学计算、自然语言处理等丰富场景，成为千行百业的等数十万客户的坚固可靠的算力底座。澎湃算力性能极致发挥，助力企业突破算力瓶颈，加速释放AI生产力。

腾讯云高性能应用服务HAI（Tencent Cloud Hyper Application Inventor），更易用的GPU智算服务，提供即开即用的澎湃算力与常见环境。预装混元、DeepSeek、LLama等20+款主流模型应用环境，为企业及开发者提供一键式的模型部署体验，并集成配套的开发工具与组件，大幅简化用户部署门槛，提高应用层的开发生产效率。

同时，HAI的推理集群能力，集成了高性能计算底座、自研优化框架、智能调度系统与全方位安全机制于一体，为客户提供极致性价比、高并发稳定、安全可信赖、全托管免运维的综合大模型推理能力。通过动态扩缩容、异步推理等技术，显著提升GPU利用率，降低单位推理成本。基于腾讯云自研的分布式调度系统，支持毫秒级弹性伸缩，轻松应对流量高峰。结合智能负载均衡与自动故障迁移，确保服务SLA达到99.95%以上。“专属隔离+机密计算”双保险机制，使每个推理集群独占物理资源，杜绝共享风险；同时支持基于英伟达hopper架构的可信芯片的机密计算能力，确保模型权重、用户数据全程加密，即使云服务商也无法窥探。此外，从底层硬件维护到上层框架升级，全部由腾讯云专业团队负责。企业无需关心K8s、CUDA驱动、推理框架版本兼容等问题，真正做到“开箱即用”。

腾讯云计算加速套件TACO Kit（Tencent Cloud Accelerated Computing Optimization Kit）主要面向生成式AI场景提供加速服务，搭配腾讯自研的软硬件协同优化组件和硬件厂商持有的优化方案，支持在物理机、云服务器、容器等产品上部署加速。包括TACO Train AI训练加速、TACO LLM推理加速、TACO DiT推理加速三个模块，其中TACO Train提供自底向上的网络通信、分布式

策略及训练框架等多层级的优化加速组件，用户可以根据需要选择适配。无需业务代码改动，即可加速分布式训练业务。支持大规模多机多卡分布式训练场景，提高加速比和模型迭代效率；TACO LLM提供面向大语言模型（LLM）推理加速引擎，为客户提供兼顾高吞吐、低时延的优化方案；TACO DiT是面向生图模型（DiT）推理加速引擎，支持单卡加速和多卡加速，专注于提升文生图、文生视频以及图生视频等场景的推理效率。TACO Kit的加速能力覆盖文生文、文生图、图生图、图生视频等多个跨模态场景，提供从训练到推理的全栈加速能力。

腾讯云智能高性能网络IHN（Tencent Cloud Intelligent High-performance Network）基于腾讯成熟的AI网络技术和运营运维体系，打造极致性能、一站式运营、软硬一体的AI网络产品。IHN作为腾讯万亿大模型的高性能网络底座，基于QP源端口预规划、端网拓扑亲和、定制加速通信库TCCL、全局拥塞调度、全局业务可视等能力，结合腾讯自研硬件设备，满足客户超大规模、超高带宽、超强可靠性的AI网络需求。

腾讯云高性能存储（Tencent Cloud AI High-Performance Storage）主要由对象存储 COS、高性能并行文件存储 CFS Turbo、数据加速器 GooseFS 和数据万象 CI 等多种产品组成，覆盖 AI 大模型业务数据采集、清洗、训练、推理和“智”理全流程，将大模型的数据清洗和训练效率提升一倍，需要的时间缩短一半，数据推理性能最高10倍提升，全方位释放数据潜能。

腾讯云向量数据库（Tencent Cloud VectorDB）是国内“首家”获得权威机构(中国信通院)认证的企业级自研分布式数据库，源自腾讯集团多年技术沉淀，稳定运行于腾讯内部多个核心业务线(例如腾讯视频、腾讯会议、QQ音乐等国民应用)，每日支撑超过3700亿次向量检索请求，可支持千亿级向量规模存储、五百万QPS及毫秒级查询延迟。向量数据库作为AGI时代的“数据枢纽”，专门用于在搜索/推荐和AIGC场景中提供文档、图片、音视频等非结构化数据的存储检索服务，是大模型落地AI应用的“最佳拍档”。腾讯云向量数据库凭借其优秀的产品性能和出色的智能化解决方案，迅速赋能产业界上下游，帮助企业加速智能化升级，从而有效促进了AGI产业生态的繁荣。

腾讯专有云智算套件是腾讯云专门帮助企业构建私有化云智算平台，具备高性能、高可用、高性价比，及完整软硬件智算生态的算存网一体智算解决方案。包括了HCC、IHN、TurboFS、TACO等产品，提供完善的高性能计算、存储、网络能力，为大模型及其上层应用提供高效能AI算力，同时搭配完整的运营和运维能力，可以满足算力自用或对外提供算力等多种智算中心场景。

腾讯云安全面对AI时代的攻防新范式，基于自身防护经验打造腾讯AI大模型安全治理框架：覆盖底层的监管要求、标准体系，从基础设施安全加固、开发阶段安全检测、到训练推理阶段的“安全基准+数据安全”，到部署阶段的“运行环境安全”，再到运维阶段的“安全运营”与应急响应能力，助力客户构建涵盖全生命周期的安全防护能力，以安全、可控、可靠的服务助力企业放心用AI，实现业务提质增效。

关于AI Infra多元硬件与智能底座

腾讯云分布式云，可将腾讯云智算完整能力从公有云输出到客户本地IDC，提供与公有云一致的服务能力以及控制台/API管理体验，主要面向有数据合规或就近低时延服务诉求的用户。基于分布式云的本地化智算部署，可以保障「客户数据不出园」满足合规诉求，也可以避免数据上下云带来的网络开销。同时分布式云云端管控、软硬托管服务特性，客户在本地IDC也无需直接负责智算服务的维护管理，享受与云上一致的便捷体验。

腾讯云智算经历公有云和自研混元大模型打磨沉淀，应对智算木桶效应，推出算存网全栈方案支持专有云、分布式云多种部署形态，灵活底座，满足客户自有GPU、自建智算中心需求，适配多种GPU芯片和网络交换机，支持混合部署，对硬件保持开放兼容。

关于 IDC

国际数据公司（IDC）是在信息技术、电信行业和消费科技领域，全球领先的专业的市场调查、咨询服务及会展活动提供商。IDC帮助IT专业人士、业务主管和投资机构制定以事实为基础的技术采购决策和业务发展战略。IDC在全球拥有超过1100名分析师，他们针对110多个国家的技术和行业发展机遇和趋势，提供全球化、区域性和本地化的专业意见。在IDC超过50年的发展历史中，众多企业客户借助IDC的战略分析实现了其关键业务目标。IDC是IDG旗下子公司，IDG是全球领先的媒体出版、会展服务及研究咨询公司。

IDC China

IDC中国（北京）：中国北京市东城区北三环东路36号环球贸易中心E座901室

邮编：100013

+86.10.5889.1666

Twitter: @IDC

blogs.idc.com

www.idc.com

版权声明

凡是在广告、新闻发布稿或促销材料中使用IDC信息或提及IDC都需要预先获得IDC的书面许可。如需获取许可，请致信 gms@idc.com。翻译或本地化本文档需要IDC额外的许可。

获取更多信息请访问www.idc.com，更多有关IDC GMS信息，请访问<https://www.idc.com/prodserv/custom-solutions>。

版权所有2025 IDC。未经许可，不得复制。保留所有权利。